



ENCE

Escola Nacional de Ciências Estatísticas

Integração de Coordenadas Geográficas na Seleção de Unidades Primárias de Amostragem com Aplicação à Amostra Mestra do IBGE

Antonia Xavier

Orientadora: Alinne de Carvalho Veiga

Coorientador: Pedro Luis do Nascimento Silva

Escola Nacional de Ciências Estatísticas

Rio de Janeiro, July 1, 2025

Sumário

Introdução

Objetivos

Principais referências bibliográficas

Cadastros Mestres e Amostras Mestras

Construção do Cadastro Mestre

Metodologia

Replicação da Amostra Mestra

Resultados Pareto

Resultados PPT-PCE

Comparação entre os planos amostrais

Considerações finais

Introdução

- Estatísticas oficiais fornecem um elemento indispensável no sistema de informação de uma sociedade democrática, servindo ao governo e ao público com dados sobre a situação econômica, demográfica, social e ambiental (ONU, 1994)
- Sistema Integrado de Pesquisas Domiciliares (SIPD).
- Amostra Mestra: uma infraestrutura amostral compartilhada que permite a extração de subamostras para atender às necessidades de diversas pesquisas.
- *Department of Economic and Social Affairs Statistics Division of United Nations* recomendou em 2005 que países em desenvolvimento adotassem amostra mestra e cadastro mestre em pesquisas domiciliares (Pettersson, 2005, p. 72).
- Aumento da relação de custo-eficiência ao longo do tempo, melhoria na qualidade dos dados, agilidade na seleção de amostras e maior integração entre diferentes pesquisas domiciliares.

- Na Amostra Mestra o plano amostral é conglomerado em diversos estágios, no qual em primeiro estágio são selecionadas unidades primárias de amostragem (UPAs), compostas por setores censitários agregados.
- Testar a aplicação de um método alternativo na seleção de UPAs, no qual se incorpora explicitamente a informação geográfica sobre as mesmas.
- PPT de Poisson Correlacionado Espacialmente (Grafström, 2012).

- A utilização de Coordenadas Geográficas nos algoritmos de Amostragem não é algo que foi testado em nenhuma pesquisa do IBGE até o momento, no entanto, já é algo documentado e utilizado em outras pesquisas ao redor do mundo.
- Favre-Martinoz et al. (2018) cita potenciais vantagens no uso de informações geoespaciais no processo de amostragem, como garantir melhor dispersão espacial e ganho de eficiência

Pergunta de pesquisa

A incorporação de coordenadas geográficas no plano amostral da Amostra Mestra do IBGE geraria quais efeitos?

Objetivos

- Objetivo geral:
 - Analisar os efeitos da integração de coordenadas geográficas no plano amostral da Amostra Mestra no que diz respeito à eficiência.
- Objetivos Específicos:
 - Replicar o algoritmo da Amostra Mestra a partir dos setores censitários agregados em UPAs da região metropolitana da capital da unidade Federativa do Paraná
 - Fazer simulações da seleção de amostras para ambos os métodos
 - Calcular a eficiência de ambos os métodos separadamente com base no cálculo da variância, erro quadrático médio e coeficiente de variação.

Sumário

Introdução

Objetivos

Principais referências bibliográficas

Cadastros Mestres e Amostras Mestras

Construção do Cadastro Mestre

Metodologia

Replicação da Amostra Mestra

Resultados Pareto

Resultados PPT-PCE

Comparação entre os planos amostrais

Considerações finais

Principais referências bibliográficas

- Freitas, M. P. S. de; Antonaci, G. de A. Sistema Integrado de Pesquisas Domiciliares: Amostra Mestra 2010 e Amostra da PNAD Contínua — Texto de Discussão nº 50.
- Arantes, S. B. (2010). Planejamento de Amostras Domiciliares no Brasil explorando a Malha Setorial do Censo Demográfico 2010.
- Favre-Martinoz et al. (2018). Capítulo sobre *Amostragem Espacial* no *Handbook of Spatial Analysis*.
- Grafström, A. (2012). Spatially Correlated Poisson Sampling (SCPS).
- Silva; Dias; Bianchini (2021). "Amostragem: Teoria e Prática usando R"

Sumário

Introdução

Objetivos

Principais referências bibliográficas

Cadastros Mestres e Amostras Mestras

Construção do Cadastro Mestre

Metodologia

Replicação da Amostra Mestra

Resultados Pareto

Resultados PPT-PCE

Comparação entre os planos amostrais


Considerações finais

Cadastros Mestres

- O custo de desenvolver um bom cadastro é geralmente alto. Cadastros mestres permitem o compartilhamento dos custos operacionais de se montar um cadastro, maior conhecimento sobre as áreas selecionadas e oportunidades para análises de dados mais ricas (Carletto et al., 2022)
- Cadastros Mestres também permitem a integração entre diferentes pesquisas domiciliares e pode trazer uma melhoria na qualidade em relação a cadastros ad hoc uma vez que será usado por um período mais longo e para um número de pesquisas
- Sistema Integrado de Pesquisas Domiciliares (SIPD): Otimização de recursos e ao aumento da eficiência na divulgação das informações exigidas pela sociedade
- Adoção de uma única amostra para todas as pesquisas do SIPD, obtida a partir de um cadastro único que contém informações de cada setor censitário e suas características sociodemográficas e informações da região administrativa, denominado Cadastro Mestre.

- **População Alvo**
 - População alvo de todas as pesquisas do SIPD (POF, PNAD, PNS)
- **Abrangência geográfica**
 - Base operacional geográfica, formulada a partir dos dados do Censo 2010.
 - Excluído setores censitários de áreas como aldeias indígenas, quartéis, bases militares, alojamentos, acampamentos, embarcações
- **Plano Amostral**
 - Um plano por conglomerado em diversos estágios, do qual são selecionadas unidades do Cadastro Mestre
 - Unidades Primárias de Amostragem são agregados de setores censitários
 - Unidades Secundárias de Amostragem são domicílios

Processo de Construção e Seleção da Amostra Mestra



Estratificação

- **Por UF**
 - 27 UFs: 26 estados e o Distrito Federal
- **Por divisão administrativa**
 - Capital
 - Região Metropolitana (RM) da Capital ou Rede Integrada de Desenvolvimento (RIDE)
 - Municípios pertencentes a colar ou expansão metropolitana ou outra RM
 - Municípios pertencentes à RIDE com sede em outra UF
 - Demais municípios
- **Por situação da UPA**
 - Urbana ou Rural
- **Estratificação Estatística**
 - Por rendimento total dos domicílios

Etapas de pré-seleção da Amostra Mestra

- **Definição do tamanho de amostra**
 - Calculado como o tamanho necessário para estimar o “total de pessoas desocupadas de 14 anos ou mais de idade”
 - 14 domicílios por UPA selecionada
- **Alocação**
 - Em duas etapas:
 - Primeiro proporcional ao número de UPAs dentro dos estratos geográficos
 - Depois proporcional ao número de UPAs por estrato final

Sumário

Introdução

Objetivos

Principais referências bibliográficas

Cadastros Mestres e Amostras Mestras

Construção do Cadastro Mestre

Metodologia

Replicação da Amostra Mestra

Resultados Pareto

Resultados PPT-PCE

Comparação entre os planos amostrais

Considerações finais

- Ambas disponíveis pelo site do IBGE
- **Malha de setores censitários**
 - Região Metropolitana do estado do Paraná
 - Código do setor, nome da UF, nome do município, situação do setor, tipo de setor censitário, geometria do setor
 - 23.899 setores censitários para o estado do Paraná, sendo 3.190 na capital e 2.967 na região metropolitana.
- **Agregado por setores censitários: Característica por domicílio (parte 1, 2 e 3)**
 - Características dos domicílios, necessária para a agregação de setores em UPAs, estratificação e seleção

Tratamento dos dados

- Malha de setores censitários
- Filtra os municípios que compõe a Região Metropolitana de Curitiba, incluindo a capital, conforme (Agência de Assuntos Metropolitanos do Paraná, 2025)
- Remoção de setores classificados como “Massas D’água” na variável `cd_sitque` detalha códigos da situação do setor;
- Excluir setores categorizados como “Quartel ou base militar”, “Alojamento ou acampamento”, “Agrupamento indígena”, “Unidade Prisional”, “Convento, hospital, instituição de longa permanência de idosos ou instituição de acolhimento a crianças e adolescentes”, “Agrovila dos Projetos de Assentamento” ou “Agrupamento quilombola” com base na variável `cd_tipo` que correspondente ao tipo de setor censitário;
- 6.100 setores censitários
- Junção esquerda com os arquivos dos agregados dos setores censitários
- Valores ausentes das variáveis de interesse imputados utilizando *hot-deck* por meio da função `hotdeck` do pacote `VIM`


Agregação dos setores em UPAs

- Previamente realizada pelo professor José André de Moura Brito (ENCE) e fornecida pelo professor coordenador
- Cada UPA deve ter pelo menos 60 DPPOs e ser formada exclusivamente por setores contíguos
- Para municípios com até 200 setores, aplica-se o algoritmo HAGM (heurística baseada em árvore geradora mínima), que consiste na geração da árvore geradora mínima desse grafo, de modo que fossem correspondidas possíveis UPAs com no mínimo 60 DPPOs.
- 5.851 UPAs, 29 municípios e 1.303.003 domicílios

Estratificação do Cadastro Mestre

- Por divisão administrativa
 - 3.087 UPAs em Curitiba
 - 2.754 na RM da Capital
- Por situação do domicílio
 - 479 UPAs (8,2%) recebem a classificação rural
 - Divisão dos estratos urbanos em “Urbano - Favela e Comunidade” e “Urbano - Não especial”.

Distribuição geográfica das UPAs por estrato geográfico



Fonte:

Elaborado pela autora com base na malha de setores censitários (IBGE, 2024).

Estratos estatísticos (finais)

- Variável estratificadora: proporção de moradores em domicílios particulares permanentes ocupados com até um banheiro
- Busca-se obter estratos homogêneos com a restrição de pelo menos 150 UPAs por estrato final
- Fornecidos pelo professor José André Brito, que implementou o método nos estratos geográficos onde pudessem ser criados pelo menos dois estratos de UPAs
- Máximo de 5 estratos estatísticos por estrato geográfico

Definição dos estratos

UF					
Paraná					
Tipo de município					
Capital			Região Metropolitana da Capital		
Curitiba (1 município; 3087 UPAs)			Adrianópolis, Agudos do Sul, Almirante Tamandaré, Araucária, Balsa Nova, Bocaiúva do Sul, Campina Grande do Sul, Campo do Tenente, Campo Largo, Campo Magro, Cerro Azul, Colombo, Contenda, Doutor Ulysses, Fazenda Rio Grande, Itaperuçu, Lapa, Mandirituba, Piên, Pinhais, Piraquara, Quatro Barras, Rio Branco do Sul, Rio Negro, São José dos Pinhais, Quitandinha, Tijucas do Sul e Tunas do Paraná (28 municípios; 2764 UPAs)		
Situação			Situação		
Urbano (3087 UPAs)		Rural (0 UPAs)	Urbano		Rural (479 UPAs)
Favela e comunidade (234 UPAs)	Não-especial (2853 UPAs)		Favela e comunidade (272 UPAs)	Não-especial (2013 UPAs)	3 estratos estatísticos
	5 estratos estatísticos			5 estratos estatísticos	

Fonte: Elaborado pela autora.

População e Amostra por Estrato

Tipo de Município				Situação	Estrato	População	Amostra
Capital				Urbano - Favela e Comunidade	1	234	11
Capital				Urbano - não especial	1	546	25
Capital				Urbano - não especial	2	630	29
Capital				Urbano - não especial	3	554	26
Capital				Urbano - não especial	4	550	26
Capital				Urbano - não especial	5	573	27
Entorno de Região Metropolitana da Capital				Urbano - Favela e Comunidade	1	272	27
Entorno de Região Metropolitana da Capital				Urbano - não especial	1	439	43
Entorno de Região Metropolitana da Capital				Urbano - não especial	2	374	37
Entorno de Região Metropolitana da Capital				Urbano - não especial	3	437	43
Entorno de Região Metropolitana da Capital				Urbano - não especial	4	381	37
Entorno de Região Metropolitana da Capital				Urbano - não especial	5	382	37
Entorno de Região Metropolitana da Capital				Rural	1	161	6
Entorno de Região Metropolitana da Capital				Rural	2	165	6
Entorno de Região Metropolitana da Capital				Rural	3	153	5

Sumário

Introdução

Objetivos

Principais referências bibliográficas

Cadastros Mestres e Amostras Mestras

Construção do Cadastro Mestre

Metodologia

Replicação da Amostra Mestre

Resultados Pareto

Resultados PPT-PCE

Comparação entre os planos amostrais

Considerações finais

O algoritmo para a seleção do PPT de Pareto apresentado para selecionar uma amostra de tamanho n , utilizando uma quantidade x é uma variável auxiliar com valores conhecidos, de forma que $X = \sum_{i=1}^N x_i$ por Silva, Dias e Bianchini (2021):

1. Gere um número aleatório uniforme independente A_i para cada unidade i da população.
2. Calcule a *probabilidade de inclusão desejável* da unidade i : $\lambda_i = \frac{nx_i}{X}$
3. Calcule o número aleatório modificado $C_i = \frac{A_i(1-\lambda_i)}{(1-A_i)\lambda_i}$
4. Ordene as unidades crescentemente segundo valores dos números aleatórios modificados C_i
5. Selecione para a amostra as n unidades com os menores valores de C_i .

PPT de Poisson Correlacionado Espacialmente

1. A primeira unidade é incluída com a probabilidade

$$\pi_1^{(0)} = \pi_1$$

2. Se a primeira unidade for incluída definimos a indicadora I_1 como $I_1 = 1$, caso o contrário $I_1 = 0$
3. Para cada passo j , após as indicadoras $I_1, \dots, I_{j-1}$ terem sido registradas, a unidade j é incluída com probabilidade $\pi_j^{(j-1)}$
4. As probabilidades de inclusão para as unidades restantes ($i = j + 1, \dots, N$) são então atualizadas utilizando a regra:

$$\pi_i^{(j)} = \pi_i^{(j-1)} - (I_j - \pi_j^{(j-1)})w_j^{*(i)}$$

Onde $w_j^{*(i)}$ são os pesos que a unidade j atribui às unidades $i = j + 1, \dots, N$. e este peso é uma função de alguma relação de distância entre as unidades i, j e obedecem a restrição:

PPT de Poisson Correlacionado Espacialmente

Onde $w_j^{*(i)}$ são os pesos que a unidade j atribui às unidades $i = j + 1, \dots, N$. e este peso é uma função de alguma relação de distância entre as unidades i, j e obedecem a restrição:

$$- \min \left(\frac{1 - \pi_i^{(j-1)}}{1 - \pi_j^{(j-1)}}, \frac{\pi_i^{(j-1)}}{\pi_j^{(j-1)}} \right) \leq w_j^{*(i)} \leq \min \left(\frac{\pi_i^{(j-1)}}{1 - \pi_j^{(j-1)}}, \frac{1 - \pi_i^{(j-1)}}{\pi_j^{(j-1)}} \right) \quad (1)$$

Ressalta-se que, para a unidade j , $\pi_j^{(k)} = I_j$ para $k \geq j$.

Este processo de atualização gradual do vetor de probabilidades de inclusão continua por N passos, até que o vetor se transforme no vetor de indicadores de inclusão final $(I_1, I_2, \dots, I_N)$

Parâmetros de interesse

- Domicílios Particulares Permanentes Ocupados que utilizam rede geral de distribuição;
- Domicílios Particulares Permanentes Ocupados que possuem água encanada na casa, tipo de espécie é casa;
- Domicílios Particulares Permanentes Ocupados que possuem esgoto ligado à rede geral ou pluvial;
- Domicílios Particulares Permanentes Ocupados que possuem fossa séptica não ligada à rede;
- Domicílios Particulares Permanentes Ocupados que o lixo é coletado por serviço de limpeza;
- Domicílios Particulares Permanentes Ocupados que o lixo queimado na propriedade.

Sumário

Introdução

Objetivos

Principais referências bibliográficas

Cadastros Mestres e Amostras Mestras

Construção do Cadastro Mestre

Metodologia

Replicação da Amostra Mestre

Resultados Pareto

Resultados PPT-PCE

Comparação entre os planos amostrais

Considerações finais

Replicação da Amostra Mestra

- Resultados baseados no Cadastro Mestre construído a partir dos arquivos da malha de setores censitários do Censo Demográfico de 2022 e do agregado por setores censitários.
- Replicação de seleção da Amostra Mestra usando o PPT de Pareto e PPT de Poisson Correlacionado Espacialmente.
- Avaliação comparativa dos resultados obtidos pelos dois métodos, onde utilizam-se as mesmas variáveis de interesse no cálculo dos mesmos parâmetros.
- Avalia-se a variância (no caso do plano da Amostra Mestra), o erro quadrático médio e o coeficiente de variação para ambos.

Variáveis de Interesse

Variável de Interesse	Notação	Valor
Total de DPPOs que utilizam a rede geral de distribuição	Y_1	1.218.933
Total de DPPOs com água encanada na casa, onde o tipo de espécie é casa	Y_2	965.986
Total de DPPOs onde esgoto ligado à rede geral ou pluvial	Y_3	1.104.397
Total de DPPOs onde há fossa séptica não ligada à rede	Y_4	98.946
Total de DPPOs onde o lixo é coletado por serviço de limpeza	Y_5	1.215.426
Total de DPPOs onde o lixo é queimado na propriedade	Y_6	15.371
Proporção de DPPOs que utilizam a rede geral de distribuição	p_1	93,5%
Proporção de DPPOs com água encanada na casa, onde o tipo de espécie é casa	p_2	74,1%
Proporção de DPPOs onde esgoto ligado à rede geral ou pluvial	p_3	84,8%
Proporção de DPPOs com fossa séptica não ligada à rede	p_4	7,6%
Proporção de DPPOs com lixo coletado por serviço de limpeza	p_5	93,3%
Proporção de DPPOs com lixo queimado na propriedade	p_6	1,2%

Table: Fonte: Elaborado pela autora.

- $M = 5.851$ UPAs
- $N = 1.303.003$ domicílios
- $H = 15$ estratos
- $m = 385$

Simulações Pareto

- Adicionou-se ao cadastro de UPAs a informação referente ao número de unidades a serem selecionadas em cada estrato final (m_h)
- Para cada UPA sorteou-se um número aleatório contínuo entre 0 e 1, denominado *ALEAT*, gerado com distribuição uniforme de maneira independente para cada UPA, utilizando a função `runif()` da linguagem R.
- Calculou-se para cada UPA a probabilidade de inclusão desejável da mesma, onde esta se dá pela proporção de DPPOs na UPA em relação à quantidade de DPPOs por estratos, multiplicado pelo número de unidades a serem incluídas na amostra naquele estrato.

$$\pi_{hi} = m_h \cdot \frac{N_{hi}}{N_h}$$

Simulações Pareto

1. Gerou-se de um número aleatório modificado Q_{hi} para cada UPA, segundo a fórmula:

$$Q_{hi} = \frac{ALEAT_{hi} - ALEAT_{hi} \times \pi_{hi}}{\pi_{hi} - ALEAT_{hi} \times \pi_{hi}}$$

2. Ordenou-se de forma crescente os valores de Q_{hi} e em cada estrato pegou as primeiras m_h UPAs dessa ordenação.
3. O processo foi feito para cada um dos 15 estratos e estimou-se os valores de $\hat{Y}$

$$\hat{Y} = \sum_{h=1}^H \sum_{i \in s_h} \frac{\hat{Y}_{hi}}{\pi_{hi}} \quad (2)$$

4. A partir de $\hat{Y}$ estimou-se $\hat{p}$ considerando N conhecido

$$\hat{p} = \frac{\hat{Y}}{N} \quad (3)$$

5. Foram feitas $k = 1000$ replicações

Erro Quadrático Médio e viés

- O Erro Quadrático Médio (EQM) é um critério útil para comparar estimadores quanto à sua acurácia.
- Comparamos o valor p real populacional com a estimativa calculada para cada réplica

$$EQM(\hat{p}) = \frac{1}{K} \sum_{k=1}^K (\hat{p}_k - p)^2 \quad (4)$$

- O viés é calculado como a média dos desvios entre o valor p real populacional e da estimativa desse estimador

$$Viés(\hat{p}) = \frac{1}{K} \sum_{k=1}^K (\hat{p}_k - p) \quad (5)$$

- Uma vez que dispomos de um Cadastro Mestre completo, construído a partir dos dados do censo de 2022, temos tudo necessário para calcular a variância teórica dos estimadores escolhidos da Amostra Mestra, usando todos os dados do Cadastro Mestre construído
- A variância de $\hat{Y}_h$, sob planos amostrais conglomerados em dois estágios, pode ser decomposta como a soma da componente da variância devida ao sorteio das unidades primárias de amostragem (UPAs) e da componente da variância devida ao sorteio das unidades secundárias de amostragem (USAs) (Arantes, 2012).
- Com essa variância de Y calculada em todos os estratos, é possível calcular $Var(\hat{p})$

Variância e EQM da Amostra Mestre

Variável	Var($\hat{p}$) $\times 10^6$	EQM($\hat{p}$) $\times 10^6$	Viés Relativo	CV($\hat{p}$)	
				(1)	(2)
DPPOs que utilizam a rede geral de distribuição	44,4	43,7	0,4‰	0,7%	0,7%
DPPOs que possuem água encanada na casa, tipo de espécie é casa;	277	279,1	-0,3 ‰	2,3%	2,2%
DPPOs que possuem esgoto ligado à rede geral ou pluvial	79,8	79,8	-0,1 ‰	1,1%	1,1%
DPPOs que possuem fossa séptica não ligada	62,7	66,8	-3,0 ‰	10,8%	10,4%
DPPOs que o lixo é coletado por serviço de limpeza	71,6	72,3	0,1 ‰	0,9%	0,9%
DPPOs que o lixo é queimado na propriedade	10,1	11,0	-1,2 ‰	28,1%	26,9%

Fonte: Elaborado pela autora.

Notas: (1) Simulação e (2) PPT-Pareto.

Resumo dos Resultados

- De forma geral, quanto menor o CV, maior a precisão da estimativa — sendo, portanto, desejável que esse valor seja o menor possível.
- As estimativas de proporção para as variáveis “DPPOs que utilizam a rede geral de distribuição”, “DPPOs que possuem água encanada na casa, tipo de espécie é casa”, “DPPOs que possuem esgoto ligado à rede geral ou pluvial”, “DPPOs que o lixo é coletado por serviço de limpeza” podem ser classificadas como ótimas tanto utilizando o EQM quanto a variância, de acordo com o critério de avaliação baseado no coeficiente de variação (CV).
- A estimativa da proporção de “DPPOs que possuem fossa séptica não ligada à rede geral” está na faixa que pode ser classificada como uma boa estimativa em ambos os casos.
- Já a proporção de “DPPOs que o lixo é queimado na propriedade” indicou uma precisão apenas razoável. Porém, ao estimar valores cuja incidência é próxima de zero é comum o CV ser maior e isso é da natureza da medida, não significando necessariamente que a estimativa seja ruim.

- A seleção foi realizada com a função `scps` do pacote `BalancedSampling` no R, que utiliza um vetor de probabilidades de inclusão (π_{hi}) e uma matriz auxiliar X com variáveis quantitativas padronizadas e coordenadas geográficas.
- Como o algoritmo não possui suporte à estratificação, a função `scps` foi aplicada separadamente em cada estrato. Para garantir reprodutibilidade, foi definida uma semente aleatória em cada iteração com sorteio de 15 amostras (uma por estrato).
- Para esta estratégia, empregou-se o mesmo conjunto de dados e o mesmo tratamento utilizado na seleção da amostra por PPT de Pareto. O tamanho da amostra também foi mantido idêntico, resultando na seleção de $m = 385$ UPAs.

Probabilidade de Inclusão

A mesma adotada no método de Pareto, dada por

$$\pi_{hi} = m_h \cdot \frac{N_{hi}}{N_h}$$

Matriz auxiliar

Matriz de dimensão $M_h \times 3$, utilizando os valores de latitude, longitude e probabilidade de inclusão da UPA padronizados.

Matriz Auxiliar

- A matriz auxiliar é o instrumento principal para incorporar informações geográficas ao plano amostral, construída a partir da malha de setores censitários processada com o pacote `sf`, no R.
- As geometrias dos setores foram unidas em UPAs usando a função `st_union`. A partir dessas geometrias, extraiu-se o centroide de cada UPA, obtendo as coordenadas geográficas (latitude e longitude), que compõem duas colunas da matriz X .
- A terceira coluna da matriz é composta pelas probabilidades de inclusão das UPAs.
- As três colunas foram padronizadas com a função `scale`, conforme exigido pela função `scps`, garantindo contribuição equitativa das variáveis no processo de seleção amostral.

Algumas UPAs, sua respectiva geometria (polígono) e centroides representados individualmente

UPA 4106902-1-01398




UPA 4106902-2-00097



UPA 4106902-1-02721



UPA 4119509-4-00079



Seleção da Amostra por PPT-PCE

- Como o plano amostral é estratificado, a função `scps` foi aplicada de forma independente em cada estrato $h \in H$
- Para cada amostra selecionada, estimou-se o total populacional $\hat{Y}_h$ com base na expressão

$$\hat{Y} = \sum_{h=1}^H \sum_{i \in s_h} \frac{\hat{Y}_{hi}}{\pi_{hi}} \quad (6)$$

- Os valores por estrato foram agregados para obter $\hat{Y}$ (por soma) e $\hat{p}$, considerando N conhecido.

$$\hat{p} = \frac{\hat{Y}}{N}$$

- O processo foi repetido 1000 vezes para cada uma das 6 variáveis de interesse. As sementes foram fixadas (`seed = 123 + k`) a cada repetição, garantindo que as mesmas amostras fossem sorteadas e permitindo comparabilidade entre os resultados.

Resultados da simulação

Variável	$EQM(\hat{p}) \times 10^6$	Viés relativo	$CV_{\hat{p}}$
DPPOs que utilizam a rede geral de distribuição	42,1	40,6 ‰	0,7%
DPPOs que possuem água encanada na casa, tipo de espécie é casa	184,6	1,6 ‰	1,8%
DPPOs que possuem esgoto ligado à rede geral ou pluvial	68,6	3,9 ‰	1,0%
DPPOs que possuem fossa séptica não ligada	56,5	-0,4 ‰	9,9%
DPPOs que o lixo é coletado por serviço de limpeza	60,9	-17,6‰	0,8%
DPPOs que o lixo é queimado na propriedade	8,1	0,4 ‰	24,1%

Table: Fonte: Agregado por setores censitários (IBGE, 2025). Elaborado pela autora.

Análise das Estimativas segundo o Coeficiente de Variação (CV)

- As estimativas de proporção das DPPOs que utilizam a rede geral de distribuição, cujo lixo é coletado por serviço de limpeza, que possuem água encanada em casas e que têm esgoto ligado à rede geral ou pluvial foram classificadas como ótimas, segundo os critérios baseados no CV.
- A estimativa da proporção de DPPOs com fossa séptica não ligada à rede geral foi classificada como boa, enquanto a estimativa da proporção de DPPOs cujo lixo é queimado na propriedade foi considerada razoável.
- É importante observar que ambas as variáveis com menor classificação (boa e razoável) correspondem a proporções muito baixas na população.

Variável	PPT Pareto (1)	PPT Pareto (2)	PPT-PCE
DPPOs que utilizam a rede geral de distribuição	0,7%	0,7%	0,7%
DPPOs que possuem água encanada na casa, tipo de espécie é casa	2,2%	2,3%	1,8%
DPPOs que possuem esgoto ligado à rede geral ou pluvial	1,1%	1,1%	1,0%
DPPOs que possuem fossa séptica não ligada	10,4%	10,8%	9,9%
DPPOs que o lixo é coletado por serviço de limpeza	0,9%	0,9%	0,8%
DPPOs que o lixo é queimado na propriedade	26,9%	28,1%	24,1%

*Fonte: Agregados por setores censitários (IBGE, 2025).

Notas: (1) PPT-Pareto, (2) Simulações.

Comparação dos CVs: Pareto vs PPT-PCE

- O coeficiente de variação (CV) obtido com o PPT de Pareto, quando calculado via erro quadrático médio (EQM), foi ligeiramente superior ao CV calculado pela variância.
- Para as variáveis com alta proporção populacional — como DPPOs que utilizam a rede geral de distribuição, têm o lixo coletado por serviço de limpeza e possuem esgoto ligado à rede geral ou pluvial —, não houve diferença no CV entre os métodos.
- A aplicação do PPT de Poisson Correlacionado Espacialmente (PPT-PCE) resultou em CVs inferiores aos do PPT de Pareto para quase todas as variáveis, com exceção da rede geral de distribuição. Isso evidencia ganho de eficiência ao se incorporar informação espacial na seleção amostral.

Ganhos de Precisão e Considerações Finais

- As melhorias nos CVs com o uso do PPT-PCE foram discretas na maioria das variáveis.
- A redução nos CVs indica que o uso de um plano amostral que incorpora estrutura espacial pode aumentar a precisão das estimativas sem necessidade de ampliar o tamanho da amostra.
- Apesar dos ganhos, a ausência de estimadores não viesados para a variância e o maior tempo computacional colocam o PPT-PCE em desvantagem frente ao método tradicional.

Sumário

Introdução

Objetivos

Principais referências bibliográficas

Cadastros Mestres e Amostras Mestras

Construção do Cadastro Mestre

Metodologia

Replicação da Amostra Mestra

Resultados Pareto

Resultados PPT-PCE

Comparação entre os planos amostrais

Considerações finais

Considerações sobre Resultados e Limitações

- O método PPT-PCE apresentou CVs menores ou iguais aos do PPT de Pareto, indicando maior eficiência.
- As diferenças nos CVs foram pequenas e não testadas quanto à significância estatística.
- O método PPT-PCE não possui estimador não viesado da variância, exigindo simulações repetidas.
- Tempo de execução mais elevado em comparação ao PPT-Pareto: cerca de 3 minutos por variável, frente a 2 min 10s ou 2 segundos com vetorização.

Considerações Finais e Perspectivas

- O pacote SCPS é limitado ao uso de pesos maximais com distância euclidiana, o que pode ser inadequado para regiões extensas.
- O balanceamento espacial não foi avaliado; recomenda-se o uso do Índice de Voronoi em estudos futuros.
- A metodologia apresenta potencial, mas requer atenção à escolha da métrica de distância e à implementação computacional.
- Sugere-se explorar em trabalhos futuros:
 - Estratégias de pesos alternativas (como pesos gaussianos);
 - Uso de distâncias geodésicas;
 - Outras métricas para avaliação da dispersão espacial.

- Arantes, S. B. *Planejamento de amostras domiciliares no Brasil explorando a malha setorial do Censo Demográfico 2010*. Dissertação (Mestrado) — ENCE, Rio de Janeiro, 2012.
- Barbe, P.-O.; Tillé, Y. *BalancedSampling: Balanced Sampling*. R package version 1.4.1, 2024. Disponível em: <https://CRAN.R-project.org/package=BalancedSampling>.
- Carletto, C. et al. *Positioning household surveys for the next decade*. Statistical Journal of the IAOS, v. 38, n. 4, p. 923–946, 2022.
- Comissão de Estatística da ONU. *Fundamental Principles of Official Statistics*. 1994.
- Favre-Martinoz, C. et al. *Spatial sampling*. In: Handbook of Spatial Analysis: Theory and Practical Application with R. INSEE, 2018. cap. 10. Disponível em: <https://www.insee.fr/en/statistiques/fichier/3635545/imet131-n-chapitre-10.pdf>

Referências

- Freitas, M. P. S. de; Antonaci, G. de A. *Sistema Integrado de Pesquisas Domiciliares: Amostra Mestra 2010 e Amostra da PNAD Contínua*. Texto de Discussão nº 50, 2014.
- Grafström, A. *Spatially correlated Poisson sampling*. Journal of Statistical Planning and Inference, v. 142, p. 139–147, 2012.
- Instituto Brasileiro de Geografia e Estatística (IBGE). *Malha de Setores Censitários: Censo Demográfico 2022*. Rio de Janeiro: IBGE, 2024. Disponível em: <https://biblioteca.ibge.gov.br/visualizacao/livros/liv102138.pdf>.
- Lohr, S. L. *Sampling: Design and Analysis*. Chapman and Hall/CRC, 2021.
- Pessoa, D. G. C.; Silva, P. L. N. *Análise de dados amostrais complexos*. São Paulo: Associação Brasileira de Estatística, 1998.
- Pettersson, H. *Household sample surveys in developing and transition countries*. Studies in Methods, Series F, nº 96. United Nations, 2005.
- Pitta, M. T.; Silva, P. L. do N.; Brito, J. A. de M. *Planejamento Amostral para a Pesquisa TIC Domicílios 2025*. 2025.
- Silva, P. L. do N.; Dias, A. J. R.; Bianchini, Z. M. *Amostragem: Teoria e Prática usando R*. 2021.

The background features a dark, almost black, grid pattern. Overlaid on this grid are two wavy, glowing purple lines. One line starts in the top right corner and curves downwards and to the left. The other line starts in the bottom left corner and curves upwards and to the right. These lines create a sense of movement and depth.

Obrigada!