



Instituto Brasileiro de Geografia e Estatística
Escola Nacional de Ciências Estatísticas
Bacharelado em Estatística



Integração de Coordenadas Geográficas na Seleção de Unidades Primárias de Amostragem com Aplicação à Amostra Mestra do IBGE

ANTONIA XAVIER

Rio de Janeiro

2025

ANTONIA XAVIER

Integração de Coordenadas Geográficas na Seleção de Unidades Primárias de Amostragem com Aplicação à Amostra Mestra do IBGE

Monografia apresentada à Escola Nacional de Ciências Estatísticas do Instituto Brasileiro de Geografia e Estatística, como requisito parcial à obtenção do título de Bacharel em Estatística.

Orientadora: Alinne de Carvalho Veiga

Coorientador: Pedro Luis do Nascimento Silva

Rio de Janeiro


2025

ANTONIA XAVIER

INTEGRAÇÃO DE COORDENADAS GEOGRÁFICAS NA SELEÇÃO DE
UNIDADES PRIMÁRIAS DE AMOSTRAGEM COM APLICAÇÃO À
AMOSTRA MESTRA DO IBGE

Monografia apresentada como parte das atividades para a obtenção do título de Bacharel em Estatística no curso de Estatística da Escola Nacional de Ciências Estatísticas do Instituto Brasileiro de Geografia e Estatística.

BANCA EXAMINADORA



Profa. Alinne de Carvalho Veiga

Orientadora - ENCE/IBGE



Prof. Pedro Luis do Nascimento Silva

Coorientador - SCIENCE



Prof. José André de Moura Brito

ENCE/IBGE



Prof. Maurício Franca Lila

ENCE/IBGE

Rio de Janeiro, 02 de julho de 2025

AGRADECIMENTOS

Gostaria de, primeiramente, agradecer à minha mãe, que sempre me deu mais do que suporte — me ofereceu apoio, carinho e amor ao longo de toda a minha vida.

Aos meus amigos de longa data — Camila, Isabella, Amanda, Dahn e Jean — meu amor e gratidão. Amo vocês e tenho muito orgulho da amizade linda que construímos juntos ao longo dos anos.

Durante os últimos quatro anos, sinto que aproveitei intensamente tudo o que a ENCE tinha a oferecer. Isso se deve, em grande parte, aos amigos incríveis que fiz e aos professores maravilhosos que tive a sorte de conhecer.

Agradeço especialmente aos meus orientadores, Pedro e Alinne, pelo acompanhamento, paciência e dedicação. Aos professores da banca, José André e Mauricio, agradeço pelas contribuições valiosas que enriqueceram este trabalho.

Meus amigos Uriel, Julio, Chico, André, Allex e Gabriel me apoiaram muito ao longo dessa jornada, e por isso dedico também este trabalho a eles.

RESUMO

Este trabalho analisa os efeitos da incorporação de coordenadas geográficas no plano amostral da Amostra Mestra do IBGE, com o objetivo de avaliar possíveis ganhos de eficiência na seleção das Unidades Primárias de Amostragem (UPAs). A Amostra Mestra, base para diversas pesquisas domiciliares do Instituto, é tradicionalmente selecionada por meio do método de Probabilidades Proporcionais ao Tamanho (PPT) com distribuição de Pareto. Nesta monografia, propõe-se o uso do método de PPT Poisson Correlacionado Espacialmente, que permite incorporar informações de localização geográfica à amostragem, favorecendo maior dispersão espacial das unidades.

A metodologia foi aplicada a um subconjunto da base do Censo Demográfico 2022, limitado à Região Metropolitana de Curitiba, no estado do Paraná. A partir do cadastro mestre, setores censitários foram agregados em UPAs, estratificados geograficamente e estatisticamente. Em seguida, foram selecionadas amostras por PPT de Pareto e por PPT Poisson Correlacionado Espacialmente, com estimação de totais e proporções para variáveis de interesse. As medidas de precisão foram avaliadas com base na variância (para o PPT de Pareto) e no coeficiente de variação (CV), sendo calculado também o erro quadrático médio (EQM) nas simulações com PPT Poisson Correlacionado Espacialmente.

Para a comparação, são calculadas a variância e o coeficiente de variação (CV) para o plano PPT de Pareto, e o Erro Quadrático Médio (EQM) e o CV para simulações usando o plano PPT de Poisson Correlacionado Espacialmente, utilizando as mesmas variáveis de interesse. Os resultados indicam que o plano com PPT de Poisson Correlacionado Espacialmente, que integra coordenadas geográficas, embora com melhorias discretas, apresenta ganhos de precisão. A aplicação da metodologia evidencia o potencial da amostragem espacial para melhorar a eficiência.

Palavras-chaves: Amostra Mestra; Amostragem Espacial; Amostragem Estratificada; Pesquisas Domiciliares; PPT de Poisson Correlacionado Espacialmente; Amostra Mestra; Eficiência Amostral; Informações Geográficas.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxograma do Processo de Construção e Seleção da Amostra Mestra para Pesquisas Domiciliares Baseadas no Censo Demográfico	22
Figura 2 – Esquema de Estratificação para a Amostra Mestra na versão preliminar	24
Figura 3 – Representação do Algoritmo HAGM em Pseudocódigo	31
Figura 4 – Distribuição dos municípios segundo a estratificação adotada	33
Figura 5 – Distribuição geográfica das UPAs por estrato geográfico	35
Figura 6 – Definição dos estratos	36
Figura 7 – Diferenças e similaridades entre estratificação e conglomeração	43
Figura 8 – Algumas UPAs, sua respectiva geometria (polígono) e centroides representados individualmente	62

LISTA DE QUADROS

Quadro 1 – Descrição das variáveis utilizadas, suas fontes e respectivas finalidades	28
Quadro 2 – Distribuição de UPAs por tipo de município	33
Quadro 3 – Classificação das estimativas quanto à precisão	60

LISTA DE TABELAS

Tabela 1 – Estratos finais, número de UPAs e de domicílios por estrato	37
Tabela 2 – Tamanho da Amostra Mestra e da PNAD Contínua necessário para estimar, trimestralmente, o total de pessoas desocupadas de 14 anos ou mais	37
Tabela 3 – Distribuição de UPAs na população e na amostra por tipo de município, situação e estrato estatístico: população e amostra	38
Tabela 4 – Quantidade de UPAs por estrato h	55
Tabela 5 – Parâmetros populacionais das variáveis de interesse	56
Tabela 6 – Comparação entre a variância teórica e resultados das simulações para diferentes variáveis	59
Tabela 7 – Estimativas pontuais e medidas de precisão para diferentes variáveis de interesse	64
Tabela 8 – Comparação dos coeficientes de variação para diferentes métodos de amostragem - $CV(\hat{p})$	65

SUMÁRIO

1	INTRODUÇÃO	10
1.1	Delimitação do tema	10
1.2	Justificativa	12
1.3	Objetivos	13
1.3.1	Objetivo Geral	13
1.3.2	Objetivos Específicos	13
1.4	Estrutura da Monografia	13
2	CADASTROS E AMOSTRAS MESTRAS — UM HISTÓRICO	15
3	A AMOSTRA MESTRA DO IBGE	20
3.1	Estratificação	23
3.2	Etapas de pré-seleção da Amostra Mestra (2010)	25
3.2.1	Grupos de Rotação da PNAD Contínua	25
3.2.2	Definição do Tamanho de Amostra	25
3.2.3	Alocação	26
3.3	Descrição das fontes de dados	27
3.4	Construção do Cadastro Mestre	29
3.4.1	Tratamento das variáveis de interesse	30
3.4.2	Agregação dos setores em UPAs	30
3.5	Estratificação das UPAs	32
3.5.1	Estratificação geográfica	32
3.5.2	Estratificação estatística	34
3.5.3	Alocação das UPAs	36
4	METODOLOGIA	39
4.1	Notação para população e amostra	40
4.2	Estratégias de seleção de amostra	41
4.2.1	Estratificação	41
4.2.2	Conglomeração	42
4.2.3	Amostragem em múltiplos estágios	44
4.2.4	Seleção com probabilidade proporcional ao tamanho	44
4.2.5	PPT de Pareto	45
4.2.6	PPT de Poisson	45
4.2.7	PPT de Poisson correlacionado	46
4.2.8	PPT de Poisson correlacionado espacialmente	47

4.3	Parâmetros de Interesse	49
4.4	Estimadores utilizados	50
4.4.1	Probabilidade de seleção	50
4.4.2	Estimador de Horvitz-Thompson para o total	51
4.4.3	Estimador da proporção	51
4.5	Cálculo da variância no Plano Amostral de PPT de Pareto	51
4.6	Erro quadrático médio	52
4.7	Coeficiente de variação	53
5	REPLICAÇÃO DA AMOSTRA MESTRA E AMOSTRAGEM ES- PACIAL	54
5.1	Conjunto de dados e variável de interesse	54
5.2	Cálculo dos parâmetros populacionais	56
5.3	Seleção das UPAs por PPT de Pareto	56
5.4	Resultados da simulação e cálculo da variância	58
5.5	Aplicação da metodologia alternativa	60
5.5.1	Probabilidade de inclusão	61
5.5.2	Matriz auxiliar	61
5.5.3	Seleção da amostra por PPT de Poisson Correlacionado Espacialmente . . .	63
5.5.4	Resultados da simulação	64
5.6	Comparação entre os planos amostrais	65
6	CONCLUSÃO	67
	REFERÊNCIAS	69
	ANEXOS	72
	ANEXO A – CÓDIGOS CADASTRO MESTRE	73
	ANEXO B – CÓDIGOS RESULTADOS PPT PARETO	85
	ANEXO C – CÓDIGOS PPT DE POISSON CORRELACIONADO ESPACIALMENTE	89

1 INTRODUÇÃO

1.1 Delimitação do tema

De maneira geral, estatísticas oficiais são aquelas produzidas por Institutos Oficiais de Estatística, ou seja, institutos de estatística mantidos pelo Estado. O manual de boas práticas do IBGE define estatísticas oficiais como:

São informações produzidas e disseminadas por agências governamentais, em bases regulares, regidas pela legislação em matéria de estatística e/ou regulamentos administrativos, sujeitas ao cumprimento de um sistema padronizado de conceitos, definições, unidades estatísticas, classificações, nomenclaturas e códigos, visando: retratar as condições econômicas, sociais e ambientais; fornecer subsídios para o planejamento, a execução e o acompanhamento de políticas públicas; propiciar suporte técnico para tomadas de decisões; e consolidar o exercício da cidadania ([Instituto Brasileiro de Geografia e Estatística - IBGE, 2013](#), p.15).

Estatísticas oficiais são conhecidas por serem fontes confiáveis de informações, dados e estatísticas de uma determinada população. A [Comissão de Estatística da Organização das Nações Unidas \(1994\)](#) na publicação *Principles of Official Statistics* diz que “Estatísticas oficiais fornecem um elemento indispensável no sistema de informação de uma sociedade democrática, servindo ao governo e ao público com dados sobre a situação econômica, demográfica, social e ambiental”. Ao redor do mundo, boa parte das informações disseminadas por institutos oficiais de estatística advém de pesquisas amostrais, uma vez que não é viável economicamente a realização de censos com a mesma frequência que é possível realizar pesquisas amostrais.

O documento *Household Sample Surveys in Developing and Transition Countries* elaborado pelo *Department of Economic and Social Affairs Statistics Division of United Nations* recomendou em 2005 que países em desenvolvimento adotassem amostra mestra e cadastro mestre em pesquisas domiciliares ([Pettersson, 2005](#), p. 72). Essa recomendação está motivada pelo aumento da relação de custo-eficiência ao longo do tempo, melhoria na qualidade dos dados, agilidade na seleção de amostras e maior integração entre diferentes pesquisas domiciliares.

O Instituto Brasileiro de Geografia e Estatística (IBGE) opera com um modelo de pesquisa inovador baseado no Sistema Integrado de Pesquisas Domiciliares (SIPD). Esse sistema foi desenvolvido para atender de forma mais eficaz às crescentes demandas sociais por informações detalhadas sobre domicílios, famílias e indivíduos em todo o Brasil. Entre suas principais vantagens estão a agilidade na divulgação de resultados, a viabilização de estudos longitudinais curtos e a possibilidade de análises comparativas em diferentes

contextos regionais e internacionais.

Um pilar desse sistema é a Amostra Mestra, uma infraestrutura amostral compartilhada que permite a extração de subamostras para atender às necessidades de diversas pesquisas, como a Pesquisa Nacional por Amostra de Domicílios Contínua (PNAD Contínua), a Pesquisa Nacional de Saúde (PNS) e a Pesquisa de Orçamentos Familiares (POF). Esses estudos fornecem alguns dos principais indicadores para o IBGE, cuja existência é crucial para a formulação, monitoramento e avaliação de políticas públicas, como taxas de desemprego, rendimento médio, condições de saúde e padrões de consumo das famílias.

Nessas pesquisas domiciliares, os planos amostrais são conglomerados em vários estágios, onde, em um primeiro estágio, são selecionadas unidades primárias de amostragem (UPAs) formadas por agregação de setores censitários e, depois, são selecionados domicílios (Arantes; Silva, 2013). Inicialmente, os setores censitários são agregados formando unidades Primárias de Amostragem (UPAs), e realiza-se uma estratificação das UPAs com base em características sociodemográficas dos mesmos (Freitas; Antonaci, 2014).

Cada UPA é uma unidade do Cadastro Mestre que é definida como um conjunto de unidades de áreas com seus limites bem definidos, que cobrem todo o país. Para cada uma dessas unidades são associadas informações sobre divisões administrativas, contagens populacionais e outras características sociodemográficas (IBGE, 2007). As UPAs selecionadas do cadastro mestre formam a Amostra Mestra e, a partir da mesma, são selecionadas sub-amostras, das quais as unidades são utilizadas para a seleção de domicílios nas pesquisas do SIPD.

A seleção da Amostra Mestra é feita pelo método de amostragem com Probabilidades Proporcionais ao Tamanho (PPT) de Pareto, que é um método de Amostragem por ordenação para o sorteio das UPAs, onde é utilizada a distribuição de Pareto para geração das variáveis de ordenação que auxiliam na seleção da amostra (Arantes; Silva, 2013).

A utilização de Coordenadas Geográficas nos algoritmos de Amostragem não é algo que foi testado em nenhuma pesquisa do IBGE até o momento, no entanto, já é algo documentado e utilizado em outras pesquisas ao redor do mundo. O documento (Favre-Martinoz et al., 2018.) cita potenciais vantagens no uso de informações geoespaciais no processo de amostragem como, por exemplo, garantir uma melhor dispersão espacial das unidades selecionadas, além de demonstrar ganho de eficiência quando comparados com métodos que não usam dados geoespaciais para o cálculo de um mesmo estimador.

Diante dessas considerações, este trabalho buscou testar a aplicação de um método alternativo para a seleção de UPAs, no qual se incorpora explicitamente a informação geográfica sobre as mesmas. Para isso, propõe-se utilizar o método de amostragem de PPT de Poisson Correlacionado Espacialmente, que é um método de seleção que introduz correlação negativa entre os indicadores de inclusão de unidades que estão próximas em

distância geográfica, garantindo amostras bem espalhadas pela população ([Grafström, 2012](#)).

A eficiência do PPT de Poisson Correlacionado Espacialmente foi avaliada por meio de uma comparação com o método PPT de Pareto, atualmente empregado pelo IBGE na Amostra Mestra. A avaliação se deu pela análise dos coeficientes de variação dos estimadores de variáveis a respeito dos domicílios, do erro quadrático médio e da variância desses estimadores a partir dos planos que utilizam o método PPT de Pareto e método do PPT de Poisson Correlacionado Espacialmente, permitindo determinar qual abordagem promove maior eficiência.

1.2 Justificativa

O IBGE é a principal instituição oficial de estatísticas do país e a maior referência nacional na produção de pesquisas domiciliares. Dentre os diversos indicadores produzidos por essas pesquisas, destacam-se os indicadores de desocupação e rendimento, originados da PNAD Contínua, e os indicadores de saúde, como percepção do estado de saúde e uso de drogas, tabaco e álcool, obtidos por meio da Pesquisa Nacional de Saúde. Esses e outros indicadores possuem grande relevância social e subsidiam políticas públicas em diversas áreas.

Este trabalho busca responder à seguinte pergunta de pesquisa: Quais seriam os efeitos da incorporação de coordenadas geográficas no plano amostral da Amostra Mestra do IBGE?

A realização deste estudo se torna viável graças à disponibilização, em 2024, dos dados do Cadastro Nacional de Endereços para Fins Estatísticos (CNEFE), do arquivo dos agregados por setores com os dados resumidos do Censo 2022 dos domicílios e a malha de setores censitários definitiva agora contendo informações geográficas dos setores. Esses dados permitem a consideração de aspectos espaciais no desenho amostral, como o tamanho das Unidades Primárias de Amostragem (UPAs) e as distâncias entre UPAs ou domicílios.

Investigar o impacto de novos métodos sobre a eficiência amostral é de grande interesse, uma vez que ganhos de eficiência implicam diretamente em melhorias na precisão das estimativas. Segundo ([Favre-Martinoz et al., 2018.](#)), a eficiência estatística de um método de amostragem espacial aumenta com o nível de autocorrelação espacial da variável de interesse a ser estimada.

1.3 Objetivos

1.3.1 Objetivo Geral

O objetivo geral do trabalho é analisar os efeitos da integração de coordenadas geográficas no plano amostral da Amostra Mestra no que diz respeito à eficiência.

1.3.2 Objetivos Específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

- Replicar o algoritmo da Amostra Mestra a partir dos setores censitários agregados em UPAs da região metropolitana da capital da unidade Federativa do Paraná, obtidos através de um conjunto de dados que relaciona o agregado por setores censitários e a malha de setores censitários.
- Utilizar o algoritmo de PPT de Poisson Correlacionado Espacialmente nos mesmos dados.
- Fazer simulações da seleção de amostras para ambos os métodos.
- Calcular a eficiência de ambos os métodos separadamente com base no cálculo da variância, erro quadrático médio e coeficiente de variação.

1.4 Estrutura da Monografia

Esta monografia está organizada em seis capítulos. Neste capítulo, o Capítulo 1 apresenta o tema do trabalho, a delimitação do problema, a justificativa, os objetivos gerais e específicos, bem como a relevância da proposta. No Capítulo 2, são discutidos os principais fundamentos teóricos relacionados à construção de cadastros mestres e aos métodos de amostragem probabilística, com ênfase no método de seleção com Probabilidades Proporcionais ao Tamanho (PPT) e suas variantes, além de apresentar experiências nacionais e internacionais. O Capítulo 3 descreve o banco de dados utilizado e detalha o processo de construção do cadastro mestre a partir dos setores censitários, incluindo os critérios de tratamento dos dados, agregação de setores em UPAs e estratificação. No Capítulo 4, é apresentada a metodologia de amostragem adotada, com destaque para o método de PPT de Pareto utilizado na seleção da Amostra Mestra, bem como a introdução do método de Poisson Espacialmente Correlacionado, que incorpora informação geográfica na seleção das unidades. O Capítulo 5 descreve o desenvolvimento prático da pesquisa, incluindo o passo a passo da replicação da Amostra Mestra, a execução do novo método proposto e a geração de estimativas a partir dos scripts implementados em R. Por fim, o Capítulo 6 é destinado às considerações finais, onde são discutidos os resultados obtidos,

que apontam ganho em eficiência utilizando o método de PPT de Poisson Correlacionado espacialmente, suas implicações e possíveis caminhos para trabalhos futuros.

2 CADASTROS E AMOSTRAS MESTRAS — UM HISTÓRICO

Este capítulo dá continuidade à investigação proposta no Capítulo 1 — os efeitos da incorporação de coordenadas geográficas no plano amostral da Amostra Mestra do IBGE — e contextualiza o tema por meio de uma abordagem histórica e conceitual dos elementos. São abordados conceitos sobre planos amostrais complexos, amostragem espacial e o uso de cadastros e amostras mestras por institutos oficiais de estatística, com ênfase em sua aplicação em pesquisas domiciliares.

Boa parte das pesquisas por amostragem probabilística de domicílios são conduzidas com o uso de planos amostrais complexos, independentemente de terem sido realizadas por institutos oficiais de estatística ou não. Nesses planos são aplicadas técnicas como estratificação das unidades de amostragem, conglomeração (seleção da amostra em vários estágios, com unidades compostas de amostragem), probabilidades desiguais de seleção em um ou mais estágios e ajustes dos pesos amostrais para calibração com totais populacionais conhecidos (Silva; Pessoa; Lila, 2002).

Dados amostrais complexos são mais difíceis de serem analisados do que dados amostrais obtidos de amostras aleatórias simples uma vez que as estimativas pontuais de parâmetros descritivos da população ou de modelos são influenciadas por pesos distintos das observações (Pessoa; Silva, 1998). Entretanto, planos amostrais complexos trazem diversos ganhos no planejamento amostral, justificando sua utilização.

A estratificação é um método que consiste em dividir a população em grupos disjuntos e exaustivos (denominados estratos), com base em alguma informação auxiliar (Silva; Dias; Bianchini, 2021). Os estratos geralmente são mais homogêneos em relação à variável de interesse, o que é interessante porque quanto mais homogêneos forem os estratos, mais a estratificação permite aumentar a precisão de estimativas para a população, em comparação com planos de igual tamanho de amostra que não usam estratificação (Silva; Dias; Bianchini, 2021).

Além dos ganhos em eficiência do plano amostral também há outros benefícios que justificam o uso de planos estratificados, como garantir um espalhamento da amostra em distintos subgrupos, tendo assim uma amostra mais representativa da população assegurando que todas as partes (estratos) relevantes da população sejam incluídas na amostra e permitir controlar a precisão esperada de estimativas para subgrupos da população de pesquisa (Silva; Dias; Bianchini, 2021).

A amostragem com probabilidades proporcionais ao tamanho (PPT) é um conjunto

de métodos onde as unidades da população têm probabilidades distintas de seleção, proporcionais a uma medida de tamanho associada a cada unidade (Silva; Dias; Bianchini, 2021). Os métodos PPT são interessantes quando a variação dos tamanhos das unidades for grande e exista uma informação auxiliar precisa disponível sobre os tamanhos que seja correlacionada positivamente com as variáveis de interesse, uma vez que tais métodos permitem aumentar a eficiência na estimação de totais e médias, em comparação com métodos de amostragem com probabilidades iguais, para tamanhos de amostra idênticos (Silva; Dias; Bianchini, 2021).

A amostragem conglomerada consiste num esquema de amostragem em estágios, sendo que em cada estágio a unidade amostral é formada por grupos ou subconjuntos (conglomerados) de unidades populacionais. É vantajosa quando o cadastro de unidades elementares não existir ou não puder ser construído, ou se o custo de construí-lo ou atualizá-lo for muito elevado (Silva; Dias; Bianchini, 2021).

A amostragem por conglomerados é bastante útil quando o objetivo é otimizar os recursos para se chegar à unidade elementar final (Arantes, 2012). De maneira geral amostragem conglomerada impõe vantagens (menor custo) e desvantagens (menor precisão) (Silva; Dias; Bianchini, 2021). Em conglomerados onde há uma relativa homogeneidade, é necessário um tamanho de amostra de conglomerados maior, pois a variabilidade interna é menor e, conseqüentemente, cada conglomerado é menos representativo da variabilidade que ocorre na população. Por outro lado, em conglomerados mais heterogêneos, a amostragem se torna mais eficiente, pois há uma certa variabilidade que contribui para o retrato populacional (Arantes, 2012).

Diversas pesquisas domiciliares foram conduzidas pelo IBGE nas últimas décadas com diferentes objetivos, periodicidades, abrangências demográficas e níveis de complexidade (Bianchini; Albieri, 2003). Apesar dessas diferenças, Bianchini e Albieri (2003) indicou que, mesmo antes da implementação da Amostra Mestra, essas pesquisas já haviam sido planejadas de maneira semelhante. Com o tempo, foram desenvolvidos projetos e pesquisas visando à otimização de recursos e ao aumento da eficiência na divulgação das informações exigidas pela sociedade. O Sistema Integrado de Pesquisas Domiciliares (SIPD) foi concebido como resultado desse esforço (Arantes, 2012).

Uma das principais características do SIPD foi a adoção de uma única amostra de área denominada Amostra Mestra, obtida a partir de um cadastro único que contém informações de cada setor censitário e suas características sociodemográficas e informações da região administrativa, denominado Cadastro Mestre (Arantes, 2012).

Pettersson (2005) justificou a criação de um Cadastro Mestre e desenvolvimento de uma Amostra Mestra por parte de Institutos Oficiais de Estatística para países em desenvolvimento e em transição, com a justificativa de que, nesses países, os Institutos Oficiais de Estatísticas são as maiores fontes de estatísticas de qualidade e de que o

uso de um cadastro comum de unidades primárias de amostragem melhora a relação custo-benefício das pesquisas.

Isso se dá porque o custo de desenvolver um bom cadastro é geralmente alto. Cadastros mestres permitem o compartilhamento dos custos operacionais de se montar um cadastro, maior conhecimento sobre as áreas selecionadas e oportunidades para análises de dados mais ricas (Carletto et al., 2022).

Além disso, a adoção de um Cadastro Mestre facilita a integração entre diferentes pesquisas domiciliares e pode trazer uma melhoria na qualidade em relação a cadastros *ad hoc* uma vez que será usado por um período mais longo e para um número de pesquisas, justifica maiores investimentos em sua qualidade e manutenção. Além disso, um Cadastro Mestre atualizado e flexível simplifica e agiliza a seleção de amostras, possibilitando a extração rápida e de boa qualidade de amostras para diferentes pesquisas (Pettersson, 2005).

A Amostra Mestra é um instrumento poderoso de coordenação, se não mesmo de integração, de pesquisas domiciliares, que poderiam dessa forma passar a compartilhar os custos da atualização periódica da base cadastral, sem falar na adoção de bases conceituais comuns para a definição das unidades de pesquisa e amostragem (Silva, 2001).

O Brasil não é o único país do mundo a ter um Cadastro Mestre e uma Amostra Mestra utilizados por institutos oficiais de estatísticas. Por exemplo, o *Instituto Nacional de Estadística y Censos* (INDEC), da Argentina, possui uma Amostra Mestra probabilística, conglomerada, estratificada por áreas. Nessa Amostra, as UPAs são aglomerados urbanos e USAs são setores censitários. As UPAs são selecionadas com Amostragem Sistemática Proporcional ao Tamanho e as USAs são selecionadas com probabilidade proporcional ao tamanho; em ambos, o tamanho é definido pela quantidade de moradores (Muiños, 2018).

Na Colômbia, o *Departamento Administrativo Nacional de Estadística* (DANE) gerencia o Cadastro Mestre, conforme a (Departamento Administrativo Nacional de Estadística (DANE), 2016). Esse cadastro inclui um inventário cartográfico e listas de domicílios, atualizados regularmente. A amostra da *Gran Encuesta Integrada de Hogares* (GEIH) é probabilística, multietápica e estratificada por critérios geográficos (departamentos) e socioeconômicos (como necessidades básicas não satisfeitas). Municípios com mais de 7.000 habitantes são considerados UPAs por si só, enquanto áreas rurais são agregadas de acordo com os setores censitários. As capitais e regiões metropolitanas são autorrepresentadas e possuem probabilidade de seleção 1; as demais UPAs são estratificadas e selecionadas com base em uma técnica denominada Técnica de Seleção Controlada, proposta por Goodman, e Kish L. (1950, apud DANE, 2016) (Departamento Administrativo Nacional de Estadística (DANE), 2016).

Em Bangladesh, o *Bangladesh Bureau of Statistics* (BSS) desenvolveu um Cadastro

Mestre conforme o estudo ([Maligalig et al., 2013](#)). Esse sistema permite a integração de estágios amostrais em pesquisas domiciliares e sua justificativa de criação foi a diminuição de custos a longo prazo. [Maligalig et al. \(2013\)](#) cita a utilização da Amostra Mestra de Bangladesh na Pesquisa de Mercado de Trabalho organizada pelo BSS entre 2009 e 2010. O plano amostral é um conglomerado multiestágios, utilizando unidades primárias de amostragem (UPAs) compostas por áreas de enumeração com mais de 40 domicílios estratificadas geograficamente por província e por tipo de área (urbana/rural), e a seleção das UPAs é feita dentro de cada estrato utilizando amostragem sistemática.

Além dos casos apresentados, verificou-se que diversos outros países também utilizam Cadastros Mestres e Amostras Mestras, não apenas em pesquisas domiciliares, mas também em levantamentos voltados a outras áreas, como as pesquisas agropecuárias. No entanto, optou-se por mencionar apenas os três exemplos aqui destacados — Argentina, Colômbia e Bangladesh — por apresentarem características metodológicas relevantes e distintas entre si, que ilustram bem a diversidade de abordagens adotadas internacionalmente no uso dessas infraestruturas amostrais.

[Favre-Martinoz et al. \(2018.\)](#) citou que, independentemente do método de coleta de dados, a informação geográfica torna possível, dadas certas condições, melhorar a precisão das estimativas utilizando métodos de amostragem espacial. Existem diversos algoritmos para a seleção de amostras que usam informações georreferenciadas, como, por exemplo, o PPT de Poisson espacialmente correlacionada, o método Local-Pivotal e o método do Cubo.

O método de PPT de Poisson Correlacionado Espacialmente (PPT-PCE) pode ser utilizado para produzir amostras com probabilidades desiguais bem distribuídas pela população em uma, duas ou mais dimensões ([Grafström, 2012](#)). A utilização de PPT-PCE permitiu a seleção de amostras balanceadas de unidades com probabilidades de seleção desiguais. [Grafström \(2012\)](#) citou como exemplo o seu uso na catalogação de espécies, onde amostras espacialmente balanceadas já se provaram mais eficientes. O autor também comparou o PPT-PCE com outros métodos que não usam coordenadas geográficas, onde o PPT-PCE se mostrou mais eficiente.

Outro trabalho que utilizou o método PPT-PCE foi [Matei et al. \(2023\)](#), onde foi proposta uma estratégia de amostragem coordenada que produz um duplo-controle de sobrecarga de respostas a unidades não-desejadas (respondentes frequentes). Os autores então combinam o PPT de Poisson Correlacionado Espacialmente com uma explícita medida de carga de resposta acumulada, utilizando dados de pesquisas empresariais e o método Monte Carlo para fazer simulações.

Dado este contexto, esta monografia busca avaliar o impacto potencial do uso de coordenadas geográficas na eficiência dos planos amostrais, com foco na Amostra Mestra do IBGE. No capítulo seguinte, apresenta-se em maior detalhe a estrutura da Amostra

Mestra utilizada no Brasil pelo IBGE, destacando seu papel no Sistema Integrado de Pesquisas Domiciliares (SIPD) e sua relação com o Cadastro Mestre.

3 A AMOSTRA MESTRA DO IBGE (2010)

A Amostra Mestra do IBGE foi idealizada com o intuito de unificar a estrutura de cadastro e amostra para todas as pesquisas domiciliares. O IBGE define a amostra mestra como um conjunto de unidades de área selecionadas de um cadastro, segundo um método probabilístico de seleção, a partir do qual seja possível selecionar subamostras para atender às diversas pesquisas (IBGE, 2007).

Após a consolidação do Sistema Integrado de Pesquisas Domiciliares por Amostragem (SIPD), a Amostra Mestra passou por ajustes metodológicos. Freitas e Antonaci (2014) descrevem que a população alvo da Amostra Mestra constitui-se de toda a população alvo de todas as pesquisas do SIPD e citou como exemplos a Pesquisa de Orçamentos Familiares (POF), a Pesquisa Nacional de Saúde (PNS), PNAD Contínua, entre outros. Ainda segundo Freitas e Antonaci (2014), a abrangência geográfica na Amostra Mestra que está em vigor no momento da elaboração desta monografia menciona a exclusão de áreas definidas pelo IBGE como sendo áreas com características especiais. São excluídos setores censitários de aldeias indígenas, quartéis, bases militares, alojamentos, acampamentos, embarcações, penitenciárias, colônias penais, presídios, cadeias, asilos, orfanatos, conventos, hospitais e agrovilas de projetos de assentamentos rurais e setores censitários localizados em terras indígenas.


O plano amostral da amostra mestra é conglomerado em diversos estágios. Neste plano são selecionadas unidades do Cadastro Mestre. Estas unidades contêm para cada setor censitário informações sobre a dependência administrativa e características sociodemográficas. As unidades primárias de amostragem são compostas por setores censitários agregados, buscando maximizar o número de grupos, juntando o mínimo possível com a restrição de que as UPAs deveriam ter no mínimo 60 domicílios particulares permanentes (DPPs), incluindo os ocupados, os ocupados sem entrevista realizada e os vagos, dados provenientes do Censo 2010 (Freitas; Antonaci, 2014). Além disso, as UPAs devem respeitar o critério de contiguidade, ou seja, dados dois setores na mesma UPA, deve ser possível ir do setor A ao setor B, ambos pertencentes a mesma UPA, passando exclusivamente por setores desta UPA.

De maneira geral, quando se considera o plano amostral de uma pesquisa do SIPD, o primeiro passo é caracterizado pela agregação dos setores censitários para a criação das Unidades Primárias de Amostragem, que são posteriormente estratificadas e selecionadas por meio do algoritmo de Probabilidades Proporcionais ao Tamanho de Pareto (PPT de Pareto), no qual o tamanho é definido pelo número de domicílios particulares permanentes ocupados (DPPOs). Os domicílios são Unidades Secundárias de Amostragem e sua seleção

é realizada posteriormente. Também se estabelece que um domicílio selecionado para a amostra da PNAD Contínua apenas pode retornar a essa mesma pesquisa após o intervalo de 10 anos (Freitas; Antonaci, 2014). Essa decisão é tomada para que se evite a sobrecarga do informante e o esgotamento da pesquisa. Com essa restrição, a seleção dos domicílios para cada pesquisa é realizada por meio de Amostragem Aleatória Simples dentro de cada UPA selecionada no primeiro estágio.

O fluxograma apresentado na Figura 1 ilustra as etapas para a criação da Amostra Mestra, conforme descrito no documento Freitas e Antonaci (2014)

Figura 1 – Fluxograma do Processo de Construção e Seleção da Amostra Mestra para Pesquisas Domiciliares Baseadas no Censo Demográfico



Fonte: Elaborado pela autora com base no texto de (Freitas; Antonaci, 2014)

3.1 Estratificação


A estratificação é feita em várias etapas. A primeira é por UF, onde são consideradas 27 unidades federativas, sendo 26 estados e o Distrito Federal. Depois, em cada uma das UFs, os municípios são classificados de acordo com as categorias, segundo (Freitas; Antonaci, 2014):

- Capital;
- Demais municípios pertencentes à Região Metropolitana da Capital ou à Região Integrada de Desenvolvimento (RIDE), se existirem;
- Municípios pertencentes a colar¹ ou expansão metropolitana ou a outra Região Metropolitana, caso existam;
- Municípios pertencentes à RIDE com sede em outra UF, caso existam;
- Demais municípios da UF.

A Figura 2 mostra o diagrama para a estratificação a partir da Unidade Federativa, a figura apresenta o diagrama para uma versão preliminar da Amostra Mestra e não a que está em uso, por isso apresenta algumas diferenças ao que está descrito nesta monografia. Na primeira Amostra Mestra, relativa aos dados do Censo 2000 (IBGE, 2007), não existia a classificação de “Municípios pertencentes a colar ou expansão metropolitana ou a outra Região Metropolitana”. Nessa mesma edição, nos municípios que eram capitais de Unidade Federativa, foi aplicado um método de estratificação espacial nas áreas de ponderação do Censo 2000 (Aponds), que não seguiu na Amostra Mestra em vigor no momento da publicação desta monografia. Mesmo assim, a imagem foi incluída ilustra bem a ideia de hierarquia no processo de estratificação da amostra mestra até chegar aos estratos finais.

¹ Colar metropolitano é definido como "Conjunto de Municípios no entorno de uma Região Metropolitana afetados pelo processo de metropolização e que tem o objetivo de integrar o planejamento, a organização e a execução de funções públicas de interesse comum". (IBGE - Instituto Brasileiro de Geografia e Estatística, 2025)

Figura 2 – Esquema de Estratificação para a Amostra Mestra na versão preliminar



Fonte: IBGE (2007)

Na Amostra Mestra utilizada como referência, a etapa de estratificação geográfica e espacial foi implementada com o objetivo de garantir uma boa distribuição da amostra no território nacional, permitindo captar as características de diferentes áreas dentro dos estratos previamente definidos. Para isso, dentro de cada estrato, os municípios e suas respectivas UPAs foram agrupados com base em similaridades geográficas (meso e microrregiões) e com base nos conhecimentos da Coordenação de Geografia (CGEO) do IBGE. No caso das capitais, o agrupamento das UPAs considerou as divisões internas do município, como distritos, subdistritos e bairros (Freitas; Antonaci, 2014).

Dentro dos municípios, as UPAs são classificadas de acordo com a situação dos setores componentes, podendo essa ser Urbana ou Rural e, por fim, em uma última etapa, é feita uma estratificação por rendimento total dos domicílios. Essa decisão foi tomada para ter um controle de homogeneidade nas UPAs.

3.2 Etapas de pré-seleção da Amostra Mestra (2010)

Nesta seção, apresentam-se os procedimentos realizados pelo IBGE entre a estratificação e o sorteio da Amostra Mestre, conforme descrito por Freitas e Antonaci (2014). O objetivo é apresentar como o IBGE conduz essas etapas, para, em seguida, adaptar esse processo às limitações e objetivos desta monografia, com vistas à construção de um Cadastro Mestre próprio. As decisões relacionadas à alocação e ao tamanho da amostra utilizada nos resultados finais são detalhadas na Seção 3.2.3.

3.2.1 Grupos de Rotação da PNAD Contínua

A PNAD Contínua, sendo uma das principais pesquisas do SIPD, tem suas particularidades dentro da Amostra Mestra. Contudo, nessa monografia não será considerada a definição do esquema dos grupos de rotação. Essa etapa é feita depois da estratificação e antes da seleção das UPAs e é descrita detalhadamente em (Freitas; Antonaci, 2014).

3.2.2 Definição do Tamanho de Amostra

Na Amostra Mestra do IBGE, o tamanho da Amostra foi definido com base em um parâmetro relacionado à desocupação. Na primeira edição, realizada antes da PNAD Contínua ir a campo, adotou-se o parâmetro “total de pessoas desocupadas de 14 anos ou mais de idade”.

Utilizou-se o mesmo estimador de total proposto por Kish (1965). Esse estimador foi utilizado com um nível de precisão pré-estabelecido (Freitas; Antonaci, 2014). No entanto, a variância do estimador de Kish (1965) não pôde ser empregada diretamente, pois a variável de desocupação estava presente apenas nos questionários de Amostra dos

Censos de 2000 e 2010. Por esse motivo, foi necessário adotar um estimador não viciado da variância, baseado nos dados amostrais desses censos, utilizando a fórmula apresentada por Lima e Bianchini (1986).

O nível de precisão, expresso por meio do Coeficiente de Variação, foi definido individualmente para cada Unidade da Federação (UF), sendo considerados os resultados das PNADs de 2001 a 2009.

O número de domicílios selecionados por Unidade Primária de Amostragem foi fixado em 14. A escolha desse número baseou-se no estudo de Freitas e Lila (2004), que indicou que aumentos nesse valor não resultariam em uma redução significativa no tamanho da amostra de setores, dado o alto grau de homogeneidade entre os domicílios dentro de um mesmo setor.

3.2.3 Alocação

Freitas e Antonaci (2014) cita que foi necessário fazer ajustes no processo de alocação em relação à versão preliminar da Amostra Mestra devido ao esquema de rotação da PNAD contínua. A alocação da Amostra Mestra é, então, em duas etapas: primeiro, o tamanho da amostra da UF é alocado proporcionalmente ao número de UPAs em dois grupos (estratos da capital e RM, e demais estratos); segundo, dentro desses grupos, a alocação é feita proporcionalmente ao número de UPAs nos estratos finais ou ao número de DPPOs, respectivamente.

O primeiro dos ajustes citados em (Freitas; Antonaci, 2014) nos tamanhos de amostra por estrato visou atender à exigência mínima imposta pelo esquema de rotação da PNAD Contínua, que define 15 grupos de rotação, cada um devendo conter ao menos uma UPA por estrato. Em 36 estratos essa exigência não pôde ser totalmente atendida pois o número mínimo de UPAs não foi atingido. Para 24 desses 36, fixou-se o tamanho mínimo da amostra em 3 UPAs, garantindo representação nos três meses do trimestre enquanto nos 12 restantes, também foram fixadas 3 UPAs, mas com presença em apenas um mês do trimestre, pois foi possível formar apenas um grupo de rotação.

Em seguida, ajustou-se o tamanho da amostra nos estratos geográficos e espaciais para que fosse múltiplo de 12, assegurando uma distribuição uniforme da coleta ao longo das 12 semanas do trimestre. Por fim, em algumas capitais, a amostra foi ampliada para que a estimativa do total de pessoas desocupadas de 14 anos ou mais tivesse um coeficiente de variação (CV) esperado inferior a 15%.

3.3 Descrição das fontes de dados

Os dados utilizados nesta monografia são provenientes da malha de setores censitários² e do arquivo de agregados por setores censitários³, ambos extraídos do Censo Demográfico de 2022. Esses instrumentos são disponibilizados pelo IBGE e atualizados a cada edição do Censo Demográfico, estando acessíveis publicamente para todo o território nacional.

A malha de setores censitários é utilizada como subsídio para a divulgação dos agregados estatísticos resultantes do Questionário Básico do Censo Demográfico de 2022. A partir desse arquivo, obtêm-se as informações geográficas e as características de cada setor censitário, tais como o tipo e a situação do setor ([Instituto Brasileiro de Geografia e Estatística \(IBGE\), 2024](#)). A malha de setores censitários conta com 23.899 setores censitários para o estado do Paraná, sendo 3.190 na capital, 2.967 na região metropolitana e os 17.742 restantes no interior.

O arquivo de agregados por setores censitários também contém informações referentes ao Censo Demográfico de 2022, esse arquivo é essencial pois dele é obtido como o número de domicílios particulares permanentes ocupados (DPPOs), necessário para a agregação dos setores em Unidades Primárias de Amostragem (UPAs), a quantidade de moradores por DPPOs, além de variáveis socioeconômicas empregadas na estratificação.

O Quadro 1 descreve todas as variáveis necessárias e utilizadas nessa monografia, bem como sua fonte de dados.

² A malha de setores censitários está disponível no endereço <https://www.ibge.gov.br/geociencias/downloads-geociencias.html?caminho=organizacao_do_territorio/malhas_territoriais/malhas_de_setores_censitarios__divisoes_intramunicipais/censo_2022/setores/gpkg/UF> (Acesso em: 22 de maio de 2025)

³ Os arquivos de Agregados por setores censitários estão disponíveis em <https://www.ibge.gov.br/estatisticas/downloads-estatisticas.html?caminho=Censos/Censo_Demografico_022/Agregados_por_Setores_Censitarios/Agregados_por_Setor_csv/> (Acesso em: 22 de maio de 2025)

Quadro 1 – Descrição das variáveis utilizadas, suas fontes e respectivas finalidades

Variável	Descrição	Fonte	Finalidade
cd_setor	Código do setor censitário	Agregados e malha de setores	Unir os arquivos, distinguir setores
nm_UF	Nome da Unidade da Federação	Malha de setores censitários	Definir estrato (por UF)
nm_mun	Nome do município	Malha de setores censitários	Estratificação por tipo de município
cd_sit	Código da situação do setor	Malha de setores censitários	Filtrar setores fora da base operacional geográfica
cd_tipo	Tipo do setor censitário	Malha de setores censitários	Tratamento da base
situacao	Situação do setor censitário	Malha de setores censitários	Estratificação
geom	Geometria do setor (<i>shape</i>)	Malha de setores censitários	Seleção das UPAs (amostragem espacial)
V00001	Nº de domicílios particulares permanentes ocupados (DPPOs)	Agregado por setores censitários: Parte 1	Agregação em UPAs e seleção da amostra
V00005	Nº de moradores em DPPOs	Agregado por setores censitários: Parte 1	Criação da variável estratificadora
V00556	DPPOs, Apenas banheiro de uso comum a mais de um domicílio, quantidade de moradores	Agregado por setores censitários: Parte 3	Criar variável estratificadora
V00557	DPPOs, apenas sanitário ou buraco para dejeções, inclusive os localizados no terreno, quantidade de moradores	Agregado por setores censitários: Parte 3	Criar variável estratificadora
V00558	DPPOs, Não tinham banheiro nem sanitário, quantidade de moradores	Agregado por setores censitários: Parte 3	Criar variável estratificadora
V00111	DPPOs que utilizam rede de distribuição	Agregado por setores censitários: Parte 2	Variável de interesse
V00202	DPPOs tipo casa com água encanada chegando dentro da casa	Agregado por setores censitários: Parte 2	Variável de interesse
V00309	DPPOs com esgoto destinado à rede geral ou pluvial	Agregado por setores censitários: Parte 2	Variável de interesse
V00311	DPPOs com esgoto destinado a fossa séptica não ligada à rede	Agregado por setores censitários: Parte 2	Variável de interesse
V00397	DPPOs com lixo coletado por serviço de limpeza	Agregado por setores censitários: Parte 2	Variável de interesse
V00400	DPPOs com lixo queimado na propriedade	Agregado por setores censitários: Parte 3	Variável de interesse

Fonte: Fonte: Agregado por setores censitários (IBGE, 2025) e Malha de setores censitários (IBGE, 2024). Elaborado pela autora.

3.4 Construção do Cadastro Mestre

A replicação da Amostra Mestra é conduzida com fidelidade ao procedimento descrito por [Freitas e Antonaci \(2014\)](#). Entretanto, a replicação integral para o território nacional exige capacidade computacional superior à disponível, devido ao grande volume de dados envolvido. Por essa razão, neste trabalho de monografia delimita-se o escopo à região metropolitana da capital da Unidade Federativa do Paraná, cujo porte e complexidade demográfica são considerados adequados para representar a aplicação da metodologia em escala subnacional.

Para a construção do Cadastro Mestre, inicia-se utilizando-se os arquivos da malha de setores censitários do Censo Demográfico de 2022, os quais são disponibilizados pelo Instituto Brasileiro de Geografia e Estatística (IBGE) em seu portal oficial. Esta base compreende 23.899 setores censitários para toda a unidade federativa do Paraná, contendo informações político-administrativas e a geometria espacial de cada setor. Ressalta-se que a análise desenvolvida nesta monografia não leva em consideração toda a região do estado do Paraná. No entanto, optou-se por fazer o filtro para somente a região metropolitana de Curitiba, apenas após a agregação de setores em UPAs.

Antes da agregação dos setores em UPAs, realiza-se uma série de procedimentos de tratamento dos dados. São estes:

- Filtra os municípios que compõe a Região Metropolitana de Curitiba, incluindo a capital, conforme ([Agência de Assuntos Metropolitanos do Paraná, 2025](#))
- Procede-se à remoção de setores classificados como “Massas D’água” na variável `cd_sit` que detalha códigos da situação do setor;
- Excluem-se setores categorizados como “Quartel ou base militar”, “Alojamento ou acampamento”, “Agrupamento indígena”, “Unidade Prisional”, “Convento, hospital, instituição de longa permanência de idosos ou instituição de acolhimento a crianças e adolescentes”, “Agrovila dos Projetos de Assentamento” ou “Agrupamento quilombola” com base na variável `cd_tipo` que corresponde ao tipo de setor censitário;

Após esse tratamento, a base passa a ter 6.100 setores censitários.

Devido à ausência de variáveis socioeconômicas na base da malha censitária, procede-se à junção com o arquivo de agregados por setores censitários da mesma Unidade Federativa, igualmente disponibilizado pelo IBGE. Estas informações são incorporadas à base da malha de setores censitários por meio de uma junção à esquerda (*left join*), utilizando-se o `cd_setor` como chave.

A agregação dos setores censitários em Unidades Primárias de Amostragem (UPAs) foi previamente realizada pelo professor José André de Moura Brito (ENCE) e fornecida

pelo professor coorientador. Portanto, esta etapa não foi executada pela autora. No entanto, o procedimento foi detalhadamente documentado em [Pitta, Silva e Brito \(2025\)](#), com base nessas informações, será descrito na Seção 3.4.2.

3.4.1 Tratamento das variáveis de interesse

As variáveis de interesse utilizadas neste estudo estão apresentadas no Quadro 1. A seleção dessas variáveis foi realizada de forma arbitrária, considerando a disponibilidade dos dados no momento da elaboração desta monografia, bem como sua relevância social e a adequação para a estimação de proporções.

Durante a etapa de tratamento das variáveis de interesse descritas no Quadro 1, identificou-se a presença de valores ausentes ou suprimidos pelo IBGE, marcados com “X” nos arquivos originais, em decorrência de medidas para garantir o sigilo estatístico. Esses valores foram convertidos para NA e imputados utilizando o método *hot deck*, utilizando a função *hotdeck* do pacote VIM⁴ do software R.

Como variável de ordenação para o método *hot deck*, utilizou-se o número de domicílios. As variáveis de domínio consideradas foram: o município, a situação do setor (urbano ou rural) e a indicação de se o setor estava localizado em região classificada como favela ou comunidade.

3.4.2 Agregação dos setores em UPAs

As informações apresentadas nesta seção baseiam-se no documento [Pitta, Silva e Brito \(2025\)](#), o qual detalha o procedimento de agregação dos setores censitários em Unidades Primárias de Amostragem (UPAs). No trabalho indicado, a Amostra Mestra foi replicada a partir dos setores censitários, fazendo a agregação de setores em UPAs nos mesmos critérios da Amostra Mestra e utilizando diversos algoritmos de otimização combinados.

Segundo [Pitta, Silva e Brito \(2025\)](#) setores foram agregados em UPAs, respeitando as divisões de município e situação do setor (urbana ou rural) de forma que em cada UPA deve ter no mínimo 60 Domicílios Particulares Permanentes Ocupados (DPPOs) e ser formada exclusivamente por setores contíguos. Ou seja, todos os setores censitários que compõem a UPA são vizinhos, ou é possível transitar de um setor A para um setor B, ambos pertencentes à mesma UPA, passando apenas por setores igualmente pertencentes àquela unidade ([Pitta; Silva; Brito, 2025](#)).

Sendo assim, buscou-se maximizar o número de UPAs criadas ao mesmo tempo que se preservaria a contiguidade entre os setores de cada UPA, desta forma definiu-se

⁴ A documentação do pacote VIM está disponível em: <https://cran.r-project.org/web/packages/VIM/VIM.pdf>. Acesso em junho de 2025.

que o problema seria modelado como um problema de agrupamento capacitado e conexo, buscando-se a maximização de uma função associada (função objetivo) ao número de UPAs formadas.

Para a aplicação do método, considerou-se que cada setor censitário dentro de um mesmo município fosse representado como um vértice de um grafo, sendo suas vizinhanças consideradas como arestas. Estabelecidas essas relações, observou-se o número de setores por município. Para municípios com até 200 setores, aplicou-se o algoritmo HAGM (heurística baseada em árvore geradora mínima), que consiste na geração da árvore geradora mínima desse grafo, de modo que fossem correspondidas possíveis UPAs com no mínimo 60 DPPOs. A árvore geradora mínima (AGM) é, de forma simplificada, um grafo T que contém todos os n vértices do grafo G (setores) e as $n - 1$ arestas de G com os menores valores de diferença absoluta. A Figura 3 ilustra o funcionamento do algoritmo HAGM.

Figura 3 – Representação do Algoritmo HAGM em Pseudocódigo

Algoritmo HAGM

```

Construa o grafo  $G$  a partir da relação de vizinhança dos setores que compõem o município processado.
Construa a AGM  $T$  a partir de  $G$ .
 $T_{atual} \leftarrow T$ 
 $part\_viavel \leftarrow 1$ 
 $CUPA \leftarrow \emptyset$  (Conjunto de UPAs formadas)
Enquanto ( $part\_viavel=1$ ) Faça
    Remova de  $T_{atual}$  cada aresta  $a_{ij}$  e avalie o total de DPPOs nas duas partições produzidas (candidatas às UPAs)
    Se há, pelo menos, uma remoção de aresta que produz duas partições viáveis  $T_1$  e  $T_2$  Então
        Remova de  $T_{atual}$  a aresta  $a_{ij}$  que produz 2 partições com a maior diferença entre as somas dos DPPOs
         $CUPA \leftarrow CUPA \cup T_{menor}$  (subárvore correspondente à partição viável com a menor soma de DPPOs)
         $T \leftarrow T_{maior}$  (subárvore correspondente à partição viável com a maior soma de DPPOs)
    Senão
         $part\_viavel \leftarrow 0$ 
    Fim-se
Fim-Enquanto
Retorne  $CUPA$ 

```

Fonte: Pitta, Silva e Brito (2025)

Para os municípios com mais de 200 setores, considerou-se inviável a utilização do algoritmo HAGM devido ao tempo de processamento demandado. Neste caso, foi utilizado outro algoritmo baseado em grafos, denominado HN (heurística baseada em junção de nós). Nesse algoritmo, considerou-se que cada setor com 60 ou mais DPPOs formasse uma UPA individualmente, enquanto os setores com menos que isso fossem agregados com base no grafo G , visando-se à obtenção do máximo número de UPAs possíveis que fossem contíguas. Para a formação de novas UPAs, diversas combinações desses setores foram

avaliadas, priorizando-se aquelas que apresentassem menores quantitativos de setores e que atendessem aos critérios de capacidade e contiguidade (Pitta; Silva; Brito, 2025).

As UPAs criadas conforme os métodos descritos foram as referentes aos setores censitários da Capital e da Região Metropolitana da Capital, divididos conforme a classificação da situação e o tipo de setor. A situação foi considerada como “Urbana” ou “Rural”, e o tipo aplicado apenas aos recortes urbanos poderia ser “Favela ou Comunidade” ou “Não especial”.

O arquivo fornecido com os setores censitários para o Estado do Paraná conta com 14.807 UPAs, sendo 6.100 UPAs na Capital e Região Metropolitana da Capital.

Considera-se somente as UPAs com pelo menos 60 DPPOs, valor observado pela variável V00001, assim, após o descarte das observações que não atinjam esse mínimo, finaliza-se o Cadastro Mestre desta monografia com 5.851 observações em 29 municípios e 1.303.003 domicílios particulares permanentemente ocupados.

3.5 Estratificação das UPAs

3.5.1 Estratificação geográfica

Conforme explicado na seção 3.1, a estratificação foi realizada em diversas etapas, primeiramente por Unidade da Federação (UF) e, em seguida, pela divisão dos municípios conforme o tipo. Na Amostra Mestra, não foram consideradas, para a UF do Paraná, regiões metropolitanas além da Região Metropolitana de Curitiba. Como não existem Regiões Integradas de Desenvolvimento (RIDEs) na UF em questão, a estratificação por tipo de município foi realizada conforme apresentado no Quadro 2.

A definição dos municípios pertencentes à Região Metropolitana de Curitiba foi obtida a partir da Agência de Assuntos Metropolitanos do Paraná (AMEP) (Agência de Assuntos Metropolitanos do Paraná, 2025). Embora a AMEP considere outras regiões metropolitanas no Estado, como as Regiões Metropolitanas de Londrina e Maringá, optou-se por não utilizá-las neste estudo, uma vez que não foram contempladas no texto de referência da Amostra Mestra (Freitas; Antonaci, 2014). Depois da estratificação por tipo de município, cada estrato de tipo de município é dividido de acordo com o tipo de situação dos setores da UPA. Essa classificação é feita pelo IBGE e está presente na malha de setores censitários, conforme observado no Quadro 1 podendo estes serem urbanos ou rurais: 479 UPAs (8,2%) recebem a classificação rural, enquanto as 5.372 restantes (91,8%) recebem a classificação urbano.


A Figura 4 apresenta a distribuição das UPAs segundo a estratificação adotada. As áreas vazias em branco do mapa são os setores que não fazem parte do Cadastro Mestre elaborado para esta monografia.

Quadro 2 – Distribuição de UPAs por tipo de município

Tipo de Município	Municípios considerados	Quantidade de UPAs
Capital	Curitiba	3.087
Região Metropolitana da Capital	Adrianópolis, Agudos do Sul, Almirante Tamandaré, Araucária, Balsa Nova, Bocaiúva do Sul, Campina Grande do Sul, Campo do Tenente, Campo Largo, Campo Magro, Cerro Azul, Colombo, Contenda, Doutor Ulysses, Fazenda Rio Grande, Itaperuçu, Lapa, Mandirituba, Piên, Pinhais, Piraquara, Quatro Barras, Rio Branco do Sul, Rio Negro, São José dos Pinhais, Quitandinha, Tijucas do Sul e Tunas do Paraná	2.754

Fonte: ([Agência de Assuntos Metropolitanos do Paraná, 2025](#)). Elaboração própria.

Figura 4 – Distribuição dos municípios segundo a estratificação adotada



Fonte: Elaboração própria.

Conforme a descrição de (Pitta; Silva; Brito, 2025) decide-se por fazer a divisão dos estratos urbanos em “Urbano - Favela e Comunidade” e “Urbano - Não especial”. Tal decisão foi tomada para ter estratos finais mais homogêneos que pudessem respeitar a condição da Amostra Mestra de ter ao menos 150 UPAs por estrato. A Figura 5 ilustra estes estratos.

Nota-se que os setores em situação rural cobrem a maior parte da área do cadastro, no entanto, adiante será observado na figura 6 que esse estrato geográfico representa menor quantidade de UPAs, moradores e domicílios.

3.5.2 Estratificação estatística

A última etapa consiste na estratificação estatística, baseada em dados socioeconômicos. No momento em que se começou a elaboração desta monografia, a variável de rendimento total dos domicílios, utilizada para estratificação na Amostra Mestra, não estava disponível. Portanto, a variável selecionada para estratificação foi a proporção de moradores em domicílios particulares permanentes ocupados com até um banheiro. Essa proporção é dada pela soma do total de moradores em domicílios particulares permanentes ocupados que possuem exatamente um banheiro, os moradores em domicílios que possuíam sanitário ou buraco para dejeções, inclusive os localizados no terreno e os moradores em domicílios que não possuíam nenhum banheiro ou sanitário, dividido pelo total de moradores em domicílios particulares permanentes ocupados. Essa variável estratificadora foi escolhida porque Pitta, Silva e Brito (2025) em razão de seu alto poder preditivo dos níveis de renda dos setores censitários, conforme experiências de censos anteriores.


A formação de estratos estatísticos é um problema de otimização de alta complexidade computacional e sua solução é explicada detalhadamente em Brito (2017). Deve-se compor estratos homogêneos com a restrição de pelo menos 150 UPAs por estrato final, de forma a minimizar a variância por estrato de acordo com a variável estratificadora e considerando o plano amostral de amostragem conglomerada com seleção de UPAs com probabilidade proporcional ao número de domicílios (Brito, 2017).

O método de solução utilizado tem por forma de um algoritmo denominado GRASP. Trata-se de um método iterativo, onde a cada iteração encontra-se um ótimo local que, posteriormente, é melhorado mediante um procedimento de busca local.

Nesta monografia, os estratos estatísticos foram fornecidos pelo professor José André Brito da Escola Nacional de Ciências Estatísticas (ENCE), pós-doutor em otimização pela Universidade Federal Fluminense (UFF), que implementou o método nos estratos geográficos onde pudessem ser criados pelo menos dois estratos de UPAs. No algoritmo utilizado, no máximo 5 estratos estatísticos eram formados por estrato geográfico.

A Figura 6 apresenta o esquema de estratificação utilizado.

Figura 5 – Distribuição geográfica das UPAs por estrato geográfico



Fonte: Elaborado pela autora.

Figura 6 – Definição dos estratos

UF					
Paraná					
Tipo de município					
Capital			Região Metropolitana da Capital		
Curitiba (1 município; 3087 UPAs)			Adrianópolis, Agudos do Sul, Almirante Tamandaré, Araucária, Balsa Nova, Bocaiúva do Sul, Campina Grande do Sul, Campo do Tenente, Campo Largo, Campo Magro, Cerro Azul, Colombo, Contenda, Doutor Ulysses, Fazenda Rio Grande, Itaperuçu, Lapa, Mandirituba, Piên, Pinhais, Piraquara, Quatro Barras, Rio Branco do Sul, Rio Negro, São José dos Pinhais, Quitandinha, Tijucas do Sul e Tunas do Paraná (28 municípios; 2764 UPAs)		
Situação			Situação		
Urbano (3087 UPAs)		Rural (0 UPAs)	Urbano		Rural (479 UPAs)
Favela e comunidade (234 UPAs)	Não-especial (2853 UPAs)		Favela e comunidade (272 UPAs)	Não-especial (2013 UPAs)	3 estratos estatísticos
	5 estratos estatísticos			5 estratos estatísticos	

Fonte: Elaborado pela autora.

Por fim, a Tabela 1 exibe os estratos finais, com o número de UPAs e de domicílios por estrato.

3.5.3 Alocação das UPAs

A alocação consiste na definição da quantidade de unidades a serem selecionadas em cada estrato final. A Tabela 2 ilustra a alocação realizada na Amostra Mestra para a estimação de um parâmetro de interesse. As informações de total de UPAs por Unidade Federativa (UF), capital e região metropolitana, bem como pela situação do domicílio, foram obtidas das tabelas A4 e A5 Anexo 2 do documento de Freitas e Antonaci (2014).

Conforme explicado anteriormente na Seção 3.2.3, a alocação da amostra é realizada em duas etapas, seguindo o princípio da proporcionalidade. Neste trabalho, aplicamos a mesma lógica: inicialmente, manteve-se fixo o número total de UPAs amostradas em cada estrato geográfico, conforme apresentado na Tabela 2. Em seguida, esse total foi distribuído proporcionalmente entre os estratos estatísticos que compõem cada estrato geográfico, com base na quantidade de UPAs existentes em cada subgrupo da população. Em outras palavras, dentro de cada estrato geográfico, a amostra foi subdividida conforme a participação relativa de cada estrato estatístico no total de UPAs daquele estrato.

Em virtude de arredondamentos, pois os tamanhos das amostras nos estratos devem ser números inteiros, o tamanho final da amostra ficou ligeiramente superior ao planejado, totalizando 385 UPAs em vez das 384 previstas. A Tabela 3 exibe o número de UPAs na

Tabela 1 – Estratos finais, número de UPAs e de domicílios por estrato

Tipo de Muni- cípio	Situação	Estrato	UPAs	Domicílios
Capital	Urbano - Favela e Co- munidade	1	234	41.503
Capital	Urbano - não especial	1	546	112.721
Capital	Urbano - não especial	2	630	107.523
Capital	Urbano - não especial	3	554	153.669
Capital	Urbano - não especial	4	550	121.092
Capital	Urbano - não especial	5	573	147.129
Região Metropo- litana	Urbano - Favela e Co- munidade	1	272	49.178
Região Metropo- litana	Urbano - não especial	1	439	73.293
Entorno de Re- Capitalgião Me- tropolitana da	Urbano - não especial	2	374	78.054
Região Metropo- litana	Urbano - não especial	3	437	155.151
Região Metropo- litana	Urbano - não especial	4	381	91.500
Região Metropo- litanal	Urbano - não especial	5	382	100.136
Região Metropo- litana	Rural	1	161	14.581
Região Metropo- litana	Rural	2	165	33.105
Região Metropo- litana	Rural	3	153	24.368

Fonte: Malha de setores censitários (IBGE, 2024). Elaborado pela autora.

Tabela 2 – Tamanho da Amostra Mestra e da PNAD Contínua necessário para estimar, trimestralmente, o total de pessoas desocupadas de 14 anos ou mais

Tipo de Município	Situação do Domicílio	UPAs na Amostra	Total de UPAs
Capital	Urbano	144	144
	Rural	-	
Região Metropolitana	Urbano	223	240
	Rural	17	

Fonte: (Freitas; Antonaci, 2014). Elaborado pela autora

população e amostra por estrato final.

Tabela 3 – Distribuição de UPAs na população e na amostra por tipo de município, situação e estrato estatístico: população e amostra

Tipo de Município	Situação	Estrato	População	Amostra
Capital	Urbano - Favela e Comunidade	1	234	11
Capital	Urbano - não especial	1	546	25
Capital	Urbano - não especial	2	630	29
Capital	Urbano - não especial	3	554	26
Capital	Urbano - não especial	4	550	26
Capital	Urbano - não especial	5	573	27
Entorno de Região Metropolitana da Capital	Urbano - Favela e Comunidade	1	272	27
Entorno de Região Metropolitana da Capital	Urbano - não especial	1	439	43
Entorno de Região Metropolitana da Capital	Urbano - não especial	2	374	37
Entorno de Região Metropolitana da Capital	Urbano - não especial	3	437	43
Entorno de Região Metropolitana da Capital	Urbano - não especial	4	381	37
Entorno de Região Metropolitana da Capital	Urbano - não especial	5	382	37
Entorno de Região Metropolitana da Capital	Rural	1	161	6
Entorno de Região Metropolitana da Capital	Rural	2	165	6
Entorno de Região Metropolitana da Capital	Rural	3	153	5

Fonte: Elaborado pela autora.

Assim, com o Cadastro Mestre construído e estratificado, é possível selecionar amostras tanto pelo método PPT de Pareto utilizado na Amostra Mestra quanto pelo PPT de Poisson Correlacionado Espacialmente. No próximo capítulo, são formalizados os conceitos teóricos e notacionais utilizados nas etapas de seleção das unidades primárias de amostragem, com ênfase nos métodos de Probabilidades Proporcionais ao Tamanho (PPT) de Pareto e de Poisson Correlacionado Espacialmente. Também são introduzidos os estimadores utilizados, bem como as medidas adotadas para avaliação da precisão dos planos amostrais comparados.

4 METODOLOGIA

A utilização de amostragem em múltiplos estágios de seleção em pesquisas domiciliares é uma prática consolidada e amplamente adotada tanto no Brasil quanto em outros países. Entre as principais vantagens de se utilizar amostras probabilísticas, destaca-se a redução de custos e de tempo necessários para a execução completa da pesquisa. Ao coletar informações de uma parcela representativa da população, é possível otimizar o uso de recursos financeiros e humanos. Além disso, a amostragem favorece uma maior precisão nos resultados, uma vez que o trabalho com um número reduzido de unidades permite a implementação de controles de qualidade mais rigorosos em todas as etapas do processo — desde a coleta até o processamento dos dados, possibilitando uma supervisão mais detalhada e eficaz ([Cochran, 1977](#)).

De forma geral, considera-se uma população finita U composta pelas unidades $1, 2, \dots, N$, às quais estão associados os valores $y_1, y_2, \dots, y_N$. A partir dessa população, seleciona-se uma amostra s com n unidades, segundo um conjunto de probabilidades de seleção que caracterizam o plano amostral. Os valores y_i são fixos, mas tornam-se conhecidos apenas quando as respectivas unidades pertencem à amostra s ([Lohr, 2021](#)).

Os planos amostrais analisados nesta monografia são do tipo probabilístico e possuem estrutura complexa. Um plano amostral é considerado probabilístico quando as probabilidades de inclusão das unidades da população são conhecidas. Quando bem implementado, esse tipo de plano permite que se faça inferência sobre populações amplas com base em amostras relativamente pequenas ([Lohr, 2021](#)). O plano adotado também é classificado como complexo por incorporar elementos como estratificação, conglomeração e probabilidades de seleção desiguais.

Nesta monografia, são comparados dois planos amostrais: o utilizado na Amostra Mestra, que emprega o método de PPT de Pareto, e uma metodologia alternativa baseada em PPT de Poisson Correlacionado Espacialmente. Para realizar tal comparação, foi construído um Cadastro Mestre (descrito na Seção 3.4, do Capítulo 3), a partir do qual foram calculados parâmetros populacionais, realizadas simulações de sorteios independentes de amostras e estimadas a variância e o erro quadrático médio e coeficiente de variação para estimadores de diferentes variáveis de interesse.

Neste Capítulo é apresentada a fundamentação teórica necessária para a compreensão e replicação dos resultados apresentados nesta monografia. São apresentadas as estratégias de seleção utilizadas e os recursos matemáticos para o cálculo dos resultados.

4.1 Notação para população e amostra

Abaixo, apresenta-se a notação que será usada ao longo desta monografia.

- h : Índice do estrato da população
- $\{1, 2, \dots, h, \dots, H\}$: Conjunto de todos os estratos
- $\{1, 2, \dots, m, \dots, M\}$: Conjunto de todas as unidades primárias de amostragem (UPAs) da população
- M : Número total de UPAs na população
- M_h : Número de UPAs no estrato h
- m_h : Número de UPAs selecionadas no estrato h (amostra)
- N : Número total de elementos na população
- N_h : Número de elementos no estrato h
- N_{hi} : Número de elementos na UPA i do estrato h
- n : Número total de elementos na amostra
- n_h : Número de elementos da amostra no estrato h
- n_{hi} : Número de elementos na amostra da UPA i do estrato h
- y : Variável de interesse observada nas unidades da amostra
- $Y = \sum_{h=1}^H Y_h$: Total da variável de interesse na população
- $Y_h = \sum_{i=1}^{M_h} Y_{hi}$: Total da variável de interesse no estrato h
- $Y_{hi} = \sum_{j=1}^{N_{hi}} y_{hij}$: Total da variável de interesse na UPA i do estrato h
- π_{hi} : Probabilidade de inclusão da UPA i do estrato h na amostra
- S_{hi}^2 : Variância populacional da variável de interesse na UPA i do estrato h
- p : Proporção da população com a característica de interesse
- p_{hi} : Proporção de elementos com a característica de interesse na UPA i do estrato h
- $s = \{i_1, i_2, \dots, i_m\}$, com $i \in U$: Conjunto das UPAs selecionadas da população U
- $s_h = \{i \in s : i \text{ é do estrato } h\}$: Subconjunto da amostra s pertencente ao estrato h
- K : Número de replicações

4.2 Estratégias de seleção de amostra

4.2.1 Estratificação

Em uma amostra estratificada, a população é dividida em H subpopulações denominadas estratos. Os estratos são grupos mutuamente exclusivos (disjuntos) e exaustivos — ou seja, não compartilham unidades entre si e, em conjunto, abrangem toda a população. Geralmente, os estratos são mais homogêneos em relação às variáveis de interesse (Silva; Dias; Bianchini, 2021; Lohr, 2021).

A amostragem é então realizada de forma independente dentro de cada estrato. As principais vantagens da estratificação incluem o aumento da precisão das estimativas, a garantia de representatividade para subgrupos específicos da população e a flexibilidade na coleta de dados, permitindo o uso de métodos diferenciados por estrato (Cochran, 1977).

A delimitação dos estratos pode ser feita com base em diversos critérios, dependendo dos objetivos da pesquisa e das características da população. Podem ser definidos por conveniência, mas também com base em variáveis para as quais se deseja garantir certo nível de precisão, se houver mais homogeneidade dentro dos estratos do que em toda a população. É possível, por exemplo, utilizar critérios geográficos, demográficos, socioeconômicos, administrativos ou estatísticos. A escolha pode considerar desde características observáveis da população — como sexo, faixa etária, renda ou região —, até aspectos operacionais, como o método de coleta utilizado. No caso da Amostra Mestra, exemplificada no Capítulo 3, mais especificamente na seção 3.1, a estratificação adotou critérios geográficos (Unidade da Federação), administrativos (tipo de município e situação dos setores nas Unidades Primárias de Amostragem – UPAs) e estatísticos (proporção de domicílios com até um banheiro).

Uma vez definidos os estratos, é necessário decidir quantas observações serão coletadas em cada um deles — esse processo é chamado de alocação (Lohr, 2021). Um método simples é a alocação igual, em que se seleciona o mesmo número de elementos em cada estrato. No entanto, em casos onde há grande diferença na variância populacional de dentro de cada estrato, é preferível alocar os elementos em estratos de forma que minimize esta variância. A alocação ótima é um tipo de alocação onde o objetivo é ganhar o máximo de informação com o menor custo possível (Lohr, 2021). Para isso, leva em consideração o tamanho do estrato h , a variância dentro do estrato e o custo de se entrevistar uma unidade dentro do estrato h . A alocação ótima pode reduzir custos, amostrando uma fração maior de unidades maiores, além de ser eficaz quando alguns estratos são mais caros de amostrar (Lohr, 2021).

A Seção 3.2.3 descreve o processo de alocação da Amostra Mestra adotado neste trabalho, realizado em duas etapas onde, na última etapa, faz-se o que denomina-se alocação proporcional, define-se o número de UPAs a serem selecionadas em cada estrato

final com base na proporção de UPAs desse estrato em relação ao total do estrato geográfico correspondente.

A equação que determina o número de UPAs na amostra por estrato final (m_h) é

$$m_h = m_g \cdot \frac{M_h}{M_g} \quad (4.1)$$

onde:

M_h : número de UPAs no estrato final h na população;

m_g : número de UPAs no estrato geográfico g na amostra (definido na primeira etapa por alocação fixa);

M_g : número total de UPAs no estrato geográfico g .

Caso o resultado na Equação 4.1 gere resultados não inteiros, arredondou-se para o número mais próximo usando a função `round` do R.





4.2.2 Conglomeração

Em uma amostra por conglomerados, as unidades de observação na população são agregadas em unidades de amostragem maiores, chamadas conglomerados. Conglomerados, assim como estratos, são subgrupos da população; no entanto, o processo de seleção é o que difere os métodos (Lohr, 2021). A Figura 7 indica as similaridades e diferenças entre amostra estratificada e amostra conglomerada em um estágio.

A exemplo da Figura 7, suponha que a população de interesse seja representada pelos quadrados pequenos contidos dentro de quadrados maiores. Esses quadrados maiores podem ser interpretados de duas formas: como estratos ou como conglomerados. No caso de estratificação, realiza-se uma seleção independente em cada estrato h , sorteando-se diretamente os quadrados pequenos dentro de cada um. Por outro lado, ao considerar os quadrados grandes como conglomerados, a população passa a ser composta por N conglomerados (quadrados grandes). E o procedimento consiste em sortear alguns desses conglomerados e, em seguida, considerando o plano como um conglomerado em um estágio, realizar um censo dos quadrados pequenos. Para ilustrar melhor o exemplo, é possível pensar nos quadrados grandes como unidades federativas e nos pequenos como municípios, ou ainda nos grandes como empresas e nos pequenos como trabalhadores dessas empresas.

Em amostras estratificadas, a variância de um estimador $\bar{Y}$ depende da variabilidade dentro de cada estrato. Estratos mais homogêneos contribuem para estimativas mais precisas, e estratos cujas médias da variável de interesse y sejam tão distintas quanto possível. Já em amostras por conglomerados, a variância de $\bar{Y}$ está relacionada à variabilidade entre os conglomerados. Quanto mais conglomerados forem sorteados, menor será essa variância. Nesse caso, desejam-se conglomerados internamente heterogêneos, mas que apresentem pouca diferença entre as médias de y de cada conglomerado.

Figura 7 – Diferenças e similaridades entre estratificação e conglomeração

Similaridades e diferenças na amostragem estratificada e amostragem por conglomerados em um estágio	
Amostra Estratificada	Amostra por conglomerados
Cada elemento da população está em exatamente um estrato	Cada elemento da população está em exatamente um conglomerado
População de H estratos; estrato h contém N_h elementos	Conglomerados com um estágio; População de N conglomerados
	
Sorteie uma amostra de cada estrato	Sorteie uma amostra de conglomerados; observe todos os elementos nos conglomerados da amostra
	
Variância do estimador y_u depende da variabilidade dentro do estrato	O conglomerado é a unidade amostral. Quanto mais conglomerados por amostra, menor a variância. A variância em y_u depende principalmente da variância entre a média de conglomerados.
Para melhorar a precisão elementos individuais em cada estrato devem ter valores similares, mas a média dos estratos deve ser o mais diferente umas das outras possíveis	Para melhorar a precisão elementos individuais em cada conglomerado devem ser heterogêneos e a média entre conglomerados devem ser semelhantes umas das outras.

Fonte: Traduzido de (Lohr, 2021, p. 167).

As vantagens que se destacam são a possibilidade de usar planos conglomerados quando não existe cadastro das unidades elementares, a economia em deslocamento entre as unidades de coleta e o aumento de controle sobre a qualidade dos dados, uma vez que a supervisão da coleta é facilitada. A principal desvantagem é o aumento da variabilidade dos estimadores em comparação com planos amostrais que não envolvam conglomeração (Arantes; Silva, 2013).

4.2.3 Amostragem em múltiplos estágios

A seção 4.2.2 exemplifica um plano amostral por conglomerados em um estágio, no entanto, seria possível, em vez de se observar todos os elementos dos conglomerados amostra, selecionar outra amostra dentro dos conglomerados selecionados, assim se tornando um processo em dois estágios. Lohr (2021) explica a amostragem em múltiplos estágios da seguinte forma: suponha que cada unidade na população possa ser dividida em várias unidades menores, ou subunidades. Uma amostra de n unidades foi selecionada. Se as subunidades dentro de uma unidade selecionada apresentarem resultados semelhantes, parece antieconômico medi-las todas. Uma prática comum é selecionar e medir uma amostra das subunidades em qualquer unidade escolhida. Essa técnica é chamada de amostragem em dois estágios, porque a amostra é coletada em dois estágios. O primeiro é selecionar uma amostra de conglomerados, frequentemente chamadas de unidades primárias de amostragem (UPAs), e a segunda é selecionar uma amostra de unidades secundárias de amostragem (USAs) de cada UPA selecionada no estágio anterior.

O processo pode ser repetido de forma análoga para mais estágios. Na Amostra Mestra, a amostragem por conglomerados em dois estágios é utilizada, sendo as UPAs correspondentes a agregados de setores censitários e as USAs são os domicílios. Nesse caso, além das vantagens do plano por conglomerados, há uma economia maior de recursos.

4.2.4 Seleção com probabilidade proporcional ao tamanho

Os métodos de seleção com Probabilidade Proporcional ao Tamanho (PPT) são técnicas de amostragem com probabilidades desiguais. São úteis quando há grande variação no tamanho das unidades e há disponibilidade de uma informação auxiliar de tamanho que seja precisa e positivamente correlacionada com as variáveis de interesse. Tais métodos permitem aumentar a eficiência na estimação de totais e médias, em comparação com métodos de amostragem com probabilidades iguais, para tamanhos de amostra idênticos (Silva; Dias; Bianchini, 2021).

Nas próximas seções, são explorados diversos métodos de seleção baseados em probabilidades proporcionais ao tamanho (PPT). O foco principal recai sobre o PPT de Pareto (seção 4.2.5), empregado na Amostra Mestra, e o PPT de Poisson Correlacionado

Espacialmente (seção 4.2.8), utilizado no plano alternativo. Os demais planos apresentados servem a propósitos didáticos, facilitando a compreensão, visto que o PPT de Poisson Correlacionado Espacialmente evolui do PPT de Poisson Correlacionado, que, por sua vez, deriva do PPT de Poisson.

4.2.5 PPT de Pareto

A amostragem de Pareto é um dos métodos de amostragem por ordenação que utiliza probabilidade proporcional ao tamanho (PPT) (Rosén, 1997). Pode ser utilizada em desenhos que necessitem de coordenação de amostras. Neste método é possível prefixar o tamanho da amostra e estimar variâncias com boas propriedades (Arantes, 2012).

O algoritmo para a seleção do PPT de Pareto apresentado para selecionar uma amostra de tamanho n , utilizando uma quantidade x é uma variável auxiliar com valores conhecidos, de forma que $X = \sum_{i=1}^N x_i$ por Silva, Dias e Bianchini (2021):

1. Gere um número aleatório uniforme independente A_i para cada unidade i da população.
2. Calcule a *probabilidade de inclusão desejável* da unidade i : $\pi_i = \frac{nx_i}{X}$
3. Calcule o número aleatório modificado $C_i = \frac{A_i(1-\pi_i)}{(1-A_i)\pi_i}$
4. Ordene as unidades crescentemente segundo valores dos números aleatórios modificados C_i
5. Selecione para a amostra as n unidades com os menores valores de C_i .

A Amostragem PPT de Pareto é utilizada na Amostra Mestra e a sua aplicação detalhada na seleção das unidades primárias de amostragem é descrita na seção 5.3.

4.2.6 PPT de Poisson

O método de PPT de Poisson é mais simples que o PPT de Pareto. O algoritmo para selecionar uma amostra de tamanho n da população U de tamanho N consiste nos seguintes passos Silva, Dias e Bianchini (2021):

1. Para cada unidade populacional i , determine o valor da probabilidade de inclusão $\pi_i = n \cdot \frac{x_i}{X} = np_i$
2. Para cada unidade da população selecione, de forma independente, um número aleatório A_i com distribuição uniforme no intervalo $[0,1]$.
3. Inclua a unidade i na amostra se $A_i \leq \pi_i$

4.2.7 PPT de Poisson correlacionado

As informações que explicam os métodos desta seção e da seção 4.2.8 são integralmente baseadas em Grafström (2012).

Este método foi introduzido por Bondesson & Thorburn (2008) e é um método adequado para amostragem em tempo real com probabilidades de seleção desiguais (Grafström, 2012). Neste método, a cada unidade definitivamente selecionada, a probabilidade de seleção π_i das unidades restantes na lista é atualizada de acordo com uma regra de atualização específica, onde π_i é uma probabilidade de seleção pré-definida escolhida de forma proporcional ao tamanho de uma quantidade disponível a toda a população que também tenha alguma relação de proporcionalidade com a variável de interesse y . Neste método é necessário existir uma lista ordenada de unidades $i = 1, 2, \dots, N$.

Grafström (2012) descreve o funcionamento do método para selecionar uma amostra de tamanho n da população U de tamanho N , com cada unidade tendo uma probabilidade de inclusão pré-definida π_i , tal que $\sum_{i=1}^N \pi_i = n$ por PPT de Poisson Correlacionado da seguinte forma:

1. A primeira unidade é incluída com a probabilidade

$$\pi_1^{(0)} = \pi_1$$

2. Se a primeira unidade for incluída definimos a indicadora I_1 como $I_1 = 1$, caso o contrário $I_1 = 0$
3. Para cada passo j , após as indicadoras $I_1, \dots, I_{j-1}$ terem sido registradas, a unidade j é incluída com probabilidade $\pi_j^{(j-1)}$
4. As probabilidades de inclusão para as unidades restantes ($i = j + 1, \dots, N$) são então atualizadas utilizando a regra:

$$\pi_i^{(j)} = \pi_i^{(j-1)} - (I_j - \pi_j^{(j-1)})w_j^{(i)}$$

onde $w_j^{(i)}$ são os pesos que a unidade j atribui às unidades $i = j + 1, \dots, N$. É importante notar que, para a unidade j , $\pi_j^{(k)} = I_j$ para $k \geq j$.

5. Este processo de atualização gradual do vetor de probabilidades de inclusão continua por N passos, até que o vetor se transforme no vetor de indicadoras de inclusão final $(I_1, I_2, \dots, I_N)$

Os pesos $w_j^{(i)}$ determinam como a probabilidade de inclusão de uma unidade futura i é afetada pelo resultado da amostragem da unidade atual j e obedecem à restrição

$$-\min\left(\frac{1 - \pi_i^{(j-1)}}{1 - \pi_j^{(j-1)}}, \frac{\pi_i^{(j-1)}}{\pi_j^{(j-1)}}\right) \leq w_j^{(i)} \leq \min\left(\frac{\pi_i^{(j-1)}}{1 - \pi_j^{(j-1)}}, \frac{1 - \pi_i^{(j-1)}}{\pi_j^{(j-1)}}\right) \quad (4.2)$$

Os métodos PPT de Poisson e PPT de Poisson Correlacionado não são utilizados no plano alternativo sugerido, no entanto, foram incluídos neste capítulo de maneira ilustrativa, pois facilitam o entendimento do PPT de Poisson Correlacionado Espacialmente.

4.2.8 PPT de Poisson correlacionado espacialmente

O método consiste em uma modificação do PPT de Poisson Correlacionado, permitindo a seleção de amostras espacialmente balanceadas proposta por [Grafström \(2012\)](#). O foco principal é introduzir uma correlação negativa entre os indicadores de inclusão de unidades que estão próximas segundo alguma medida de distância, o que resulta em unidades adjacentes raramente aparecendo simultaneamente na amostra. Consequentemente, as amostras produzidas são bem espalhadas pela população. O pré-requisito fundamental para a aplicação deste plano é a existência de alguma distância mensurável entre as unidades do cadastro. Seu algoritmo de seleção é o mesmo do PPT de Poisson Correlacionado.

Em termos de funcionamento, o PPT de Poisson Correlacionado Espacialmente se assemelha ao PPT de Poisson Correlacionado, mas utiliza uma função de distâncias $d(i, j)$ entre as unidades, em vez de somente uma lista ordenada. De modo geral, o plano amostral de PPT de Poisson Correlacionado Espacialmente é um conjunto de estratégias de escolha de pesos para o PPT de Poisson Correlacionado. Ou seja, para selecionar uma amostra de tamanho n de uma população U de tamanho N , onde cada unidade elementar tenha uma probabilidade de seleção conhecida e pré-definida π_i proporcional ao tamanho de alguma variável auxiliar com valores conhecidos e $\sum_{i=1}^N \pi_i = n$, a seleção de uma amostra por PPT de Poisson Correlacionado Espacialmente se dá da seguinte forma:

1. A primeira unidade é incluída com a probabilidade

$$\pi_1^{(0)} = \pi_1$$

2. Se a primeira unidade for incluída definimos a indicadora I_1 como $I_1 = 1$, caso o contrário $I_1 = 0$
3. Para cada passo j , após as indicadoras $I_1, \dots, I_{j-1}$ terem sido registradas, a unidade j é incluída com probabilidade $\pi_j^{(j-1)}$
4. As probabilidades de inclusão para as unidades restantes ($i = j + 1, \dots, N$) são então atualizadas utilizando a regra:

$$\pi_i^{(j)} = \pi_i^{(j-1)} - (I_j - \pi_j^{(j-1)})w_j^{*(i)}$$

onde $w_j^{*(i)}$ são os pesos que a unidade j atribui às unidades $i = j + 1, \dots, N$. e este peso é uma função de alguma relação de distância entre as unidades i, j e obedecem a restrição:

$$-\min\left(\frac{1 - \pi_i^{(j-1)}}{1 - \pi_j^{(j-1)}}, \frac{\pi_i^{(j-1)}}{\pi_j^{(j-1)}}\right) \leq w_j^{*(i)} \leq \min\left(\frac{\pi_i^{(j-1)}}{1 - \pi_j^{(j-1)}}, \frac{1 - \pi_i^{(j-1)}}{\pi_j^{(j-1)}}\right) \quad (4.3)$$

Ressalta-se que, para a unidade j , $\pi_j^{(k)} = I_j$ para $k \geq j$.

5. Este processo de atualização gradual do vetor de probabilidades de inclusão continua por N passos, até que o vetor se transforme no vetor de indicadores de inclusão final $(I_1, I_2, \dots, I_N)$

Nesta monografia, as amostras foram selecionadas por meio da função `scps()` do pacote `BalancedSampling`¹, desenvolvido por Grafström, Prentius e Lisic (2025) disponível no ambiente R.

O pacote utiliza por padrão a distância euclidiana entre as unidades e a estratégia de Pesos Maximais que é definida em Grafström (2012). Esta estratégia de peso máximo tem a propriedade de sempre produzir amostras de tamanho fixo, desde que a soma das probabilidades de inclusão seja um número inteiro, o algoritmo que descreve esta forma de escolher os pesos para as unidades $\{1, \dots, N\}$ é dado por:

1. Comece da primeira unidade da lista $i = 1$
2. Coloque em ordem crescente as distâncias $d(i, j)$, para $j = \{i, \dots, N\}$.
3. Calcule o peso $w_j^{*(i)}$ da unidade i para as unidades j dado por

$$-\min\left(\frac{1 - \pi_i^{(j-1)}}{1 - \pi_j^{(j-1)}}, \frac{\pi_i^{(j-1)}}{\pi_j^{(j-1)}}\right) \leq w_j^{*(i)} \leq \min\left(\frac{\pi_i^{(j-1)}}{1 - \pi_j^{(j-1)}}, \frac{1 - \pi_i^{(j-1)}}{\pi_j^{(j-1)}}\right) \quad (4.4)$$

4. Verifique qual é a unidade j com menor distância de i sem peso atribuído.
5. Dê o maior peso possível a unidade j com menor distância de i . Se mais de uma unidade $j_1, j_2 \dots j_l$ for equidistante de i , essas unidades deverão receber o mesmo peso.
6. Ajuste os pesos de forma que a $\sum_j^{N-i} w_j^{*(i)} = 1$
7. Repita os passos 3, 4 e 5 até que todas as unidades tenham peso atribuído.
8. Repita o processo para todos os $i = \{1, \dots, N\}$

Independente dos pesos escolhidos para aplicar o método, a ordem das unidades na lista afeta o plano amostral. Se a ordem for alterada, as probabilidades de inclusão

¹ A documentação do pacote e endereço para *download* do pacote está disponível em: <https://cran.r-project.org/web/packages/BalancedSampling/BalancedSampling.pdf>. Acesso em junho de 2025.

de segunda ordem podem ser modificadas. Entretanto, a forma como as unidades são ordenadas não é tão relevante porque o plano amostral mantém as mesmas propriedades gerais independentemente da ordem das unidades, já que os pesos dependem das distâncias.

4.3 Parâmetros de Interesse

Pesquisas domiciliares têm como objetivo principal investigar características específicas dos domicílios e de seus moradores, que constituem as unidades da população de estudo. Para isso, define-se previamente um conjunto de variáveis que representam os parâmetros de interesse ou parâmetros-alvo da pesquisa, os quais podem ser expressos como funções dos valores dos vetores populacionais (Silva; Dias; Bianchini, 2021).

As variáveis selecionadas para estimar os parâmetros de interesse nesta monografia são:

- Domicílios Particulares Permanentes Ocupados que utilizam rede geral de distribuição;
- Domicílios Particulares Permanentes Ocupados que possuem água encanada na casa, tipo de espécie é casa;
- Domicílios Particulares Permanentes Ocupados que possuem esgoto ligado à rede geral ou pluvial;
- Domicílios Particulares Permanentes Ocupados que possuem fossa séptica não ligada à rede;
- Domicílios Particulares Permanentes Ocupados que o lixo é coletado por serviço de limpeza;
- Domicílios Particulares Permanentes Ocupados que o lixo queimado na propriedade.

A escolha dessas variáveis foi feita de forma arbitrária, considerando sua disponibilidade à época da elaboração desta monografia. O Quadro 1, apresentado na seção 3.3, mostra quais variáveis representam essas informações e os respectivos arquivos em que podem ser encontradas.

Historicamente, a estimação de totais e médias populacionais tem sido o principal motor do desenvolvimento da teoria de levantamentos amostrais (Lohr, 2021). O total populacional, denotado por Y , é definido por (Cochran, 1977) como:

$$Y = \sum_{h=1}^H \sum_{i=1}^{M_h} \sum_{j=1}^{N_{hi}} Y_{hij} = y_{111} + y_{112} + \cdots + y_{HM_h N_{hi}} \quad (4.5)$$

Ou seja, trata-se da soma da característica de interesse observada nas unidades da população. O estimador correspondente a essa quantidade está apresentado na Expressão 4.8.

Além dos totais, esta monografia também realiza o cálculo de proporções. Uma proporção representa o número de unidades que possuem determinada característica, atributo ou pertencem a uma classe pré-definida (Cochran, 1977). Em outras palavras, ela é um caso particular da média, em que $y_i = 1$ se a unidade i possui a característica de interesse, e $y_i = 0$ caso contrário (Lohr, 2021). A proporção de indivíduos com determinada característica é dada por:

$$p = \frac{\sum_{h=1}^H \sum_{i=1}^{M_h} Y_{hi}}{N} \quad (4.6)$$

O estimador dessa proporção é apresentado na Expressão 4.9.

A precisão de qualquer estimativa amostral depende tanto do método de estimação utilizado quanto do plano amostral adotado (Cochran, 1977). A Seção 4.2 apresentou os fundamentos das estratégias de seleção utilizadas na Amostra Mestra e no plano alternativo baseado em PPT com Poisson Correlacionado Espacialmente.

4.4 Estimadores utilizados

Nesta seção são apresentados os estimadores empregados para a obtenção dos resultados desta monografia. Dada a natureza complexa do plano amostral da Amostra Mestra, que incorpora estratificação, conglomeração e seleção com probabilidades desiguais (PPT), é fundamental que os estimadores considerem adequadamente essas características em sua formulação.

4.4.1 Probabilidade de seleção

Em uma amostra probabilística, cada possível amostra $s \in U$ tem uma probabilidade conhecida de ser selecionada. É interessante escolher a probabilidade de seleção de forma que se minimize a variância dos estimadores (Lohr, 2021).

Nesta monografia, as probabilidades de seleção das UPAs são desiguais e são proporcionais ao número de domicílios. A probabilidade de seleção da UPA i dentro do estrato h é dada por

$$\pi_{hi} = m_h \cdot \frac{N_{hi}}{N_h} \quad (4.7)$$

4.4.2 Estimador de Horvitz-Thompson para o total

O total populacional é o valor Y definido anteriormente na Equação 4.5. O estimador de total populacional empregado nesta monografia é o mesmo para ambos os métodos: a replicação da Amostra Mestra com PPT de Pareto e o PPT de Poisson Correlacionado Espacialmente. Este estimador é referenciado na Equação 2.3 de Arantes (2012) e na Equação 1 de Grafström (2012).

$$\hat{Y} = \sum_{h=1}^H \sum_{i \in s_h} \frac{\hat{Y}_{hi}}{\pi_{hi}} \quad (4.8)$$

onde $\hat{Y}_{hi} = \sum_{j \in a_{hi}} y_{hij} \cdot d_{hij}$, onde a_{hi} é uma amostra de unidades secundárias na UPA i do estrato h e d_{hij} é o peso condicional da unidade elementar j ser selecionada na UPA i que é um estimador de Horvitz-Thompson para o total Y_{hi} da UPA i .

Ressalta-se que não é necessária a seleção de uma amostra para investigar a eficiência do plano da Amostra Mestra, uma vez que com as informações disponíveis é possível calcular a variância teórica para os estimadores.

4.4.3 Estimador da proporção

O estimador da quantidade definida em 4.6 é dado por:

$$\hat{p} = \frac{\hat{Y}}{N} \quad (4.9)$$

4.5 Cálculo da variância no Plano Amostral de PPT de Pareto

Para verificar a eficiência do plano amostral da Amostra Mestra foi decidido utilizar a variância da proporção das variáveis discutidas anteriormente na seção 4.3. Uma vez que dispomos de um Cadastro Mestre completo, construído a partir dos dados do censo de 2022, temos tudo necessário para calcular a variância teórica dos estimadores escolhidos da Amostra Mestra, usando todos os dados do Cadastro Mestre construído, não sendo, então, necessário estimar a variância ou os estimadores de totais e proporção.

Em cada estrato h , a variância de $\hat{Y}_h$, sob planos amostrais conglomerados em dois estágios, pode ser decomposta como a soma da componente da variância devida ao sorteio das unidades primárias de amostragem (UPAs) e da componente da variância devida ao sorteio das unidades secundárias de amostragem (USAs) (Arantes, 2012). No presente caso, considera-se que a variável de interesse é uma variável indicadora, ou seja, assume apenas os valores 0 ou 1, representando categorias dicotômicas como "possui ou não possui" ou "sim ou não". A equação utilizada para o cálculo da variância segue a equação 2.15 de Arantes (2012), considerando um plano amostral conglomerado em dois estágios (Plano

AC2), com seleção das UPAs por PPT de Pareto no primeiro estágio e das USAs por AAS no segundo estágio.

$$\begin{aligned} Var(\hat{Y}_h) = \frac{M_h}{M_h - 1} & \left(\sum_{i=1}^{M_h} \frac{Y_{hi}^2}{\pi_{hi}} (1 - \pi_{hi}) - \frac{\left(\sum_{i=1}^{M_h} Y_{hi} (1 - \pi_{hi}) \right)^2}{m_h - \sum_{i=1}^{M_h} \pi_{hi}^2} \right) \\ & + \sum_{i=1}^{M_h} \left(N_{hi}^2 \cdot \left(\frac{1}{n_{hi}} - \frac{1}{N_{hi}} \right) \cdot S_{hi}^2 \right) \end{aligned} \quad (4.10)$$

onde,

$$S_{hi}^2 = N_h \cdot p_{hi} \cdot \frac{1 - p_{hi}}{N_h - 1} \quad (4.11)$$

É a variância dentro da UPA i do estrato h .

A diferença da variância calculada nesta monografia e a referenciada é que a nossa equação incorpora a estratificação, sendo assim temos uma variância de Y_h por estrato h .

A variância de $\hat{Y}$ será a soma das variâncias em todos os estratos, ou seja:

$$Var(\hat{Y}) = \sum_{h=1}^H Var(\hat{Y}_h) \quad (4.12)$$

Com essa variância calculada em todos os estratos, é possível calcular

$$Var(\hat{p}) = \frac{\sum_{h=1}^H Var(\hat{Y}_h)}{N^2} \quad (4.13)$$

4.6 Erro quadrático médio

O Erro Quadrático Médio (EQM) é um critério útil para comparar estimadores quanto à sua acurácia. Um estimador $\hat{\theta}$ da quantidade θ vai possuir acurácia se estiver próximo do valor verdadeiro da quantidade que está sendo estimada, ou seja, se o $EQM(\hat{\theta}) = E(\hat{\theta} - \theta)^2$ for pequeno (Lohr, 2021).

Foram selecionadas $K = 1000$ amostras e o erro quadrático médio foi estimado baseado na fórmula presente em Grafström (2012):

$$EQM(\hat{p}) = \frac{1}{K} \sum_{k=1}^K (\hat{p}_k - p)^2 \quad (4.14)$$

onde comparamos o valor p real populacional com a estimativa calculada para cada réplica selecionada.

É possível calcular o viés do estimador de proporção. Nesta monografia, o viés é calculado como a média dos desvios entre o valor p real populacional e da estimativa desse estimador calculada para cada réplica selecionada, como demonstra a equação:

$$Viés(\hat{p}) = \frac{1}{K} \sum_{k=1}^K (\hat{p}_k - p) \quad (4.15)$$

Por sua vez, o viés relativo de um estimador é calculado como a razão do viés do estimador e do parâmetro, apresentado por mil ($\%$).

$$VR(\hat{p}) = \frac{Viés(\hat{p})}{p} \times 1000 \quad (4.16)$$

4.7 Coeficiente de variação

O coeficiente de variação é uma medida de variabilidade relativa que não depende da unidade de medida (Lohr, 2021). O Coeficiente de Variação (CV) de uma estatística $\hat{\theta}$ é definido da seguinte forma:

$$CV(\hat{\theta}) = \frac{\sqrt{Var(\hat{\theta})}}{E(\hat{\theta})} \quad (4.17)$$

No caso da estratégia do plano da Amostra Mestra com PPT de Pareto, ao calcular a variância, o CV utilizado é dado pela equação:

$$CV(\hat{p}) = \frac{\sqrt{Var(\hat{p})}}{p} \quad (4.18)$$

Quando utilizado o EQM, o Coeficiente de variação para a proporção p utilizado foi:

$$CV(\hat{p}) = \frac{\sqrt{EQM(\hat{p})}}{p} \quad (4.19)$$

Com a fundamentação teórica e metodológica estabelecida neste capítulo, cobrindo desde a notação essencial até os detalhes dos planos amostrais complexos e estimadores, o próximo passo consiste na aplicação prática desses conceitos. O Capítulo 5 dá prosseguimento à replicação da Amostra Mestra do IBGE, utilizando o método PPT de Pareto, e à simulação de uma amostra alternativa por meio do PPT de Poisson Correlacionado Espacialmente. Serão apresentados os resultados comparativos de variância, erro quadrático médio e coeficiente de variação para as variáveis de interesse, tornando possível comparar a eficiência de cada abordagem e entender os impactos da integração de coordenadas geográficas no processo de seleção das UPAs.

5 REPLICAÇÃO DA AMOSTRA MESTRA E AMOSTRAGEM ESPACIAL

Neste capítulo, descreve-se em detalhes o procedimento adotado para a replicação da seleção da Amostra Mestra utilizando o método PPT de Poisson Correlacionado Espacialmente. Faz-se uma avaliação comparativa dos resultados obtidos pelos dois métodos, onde utilizam-se as mesmas variáveis de interesse no cálculo dos mesmos parâmetros. Serão avaliadas a variância (no caso do plano da Amostra Mestra), o erro quadrático médio e o coeficiente de variação para ambos.

5.1 Conjunto de dados e variável de interesse

Os resultados apresentados neste capítulo são baseados no Cadastro Mestre construído a partir dos arquivos da malha de setores censitários do Censo Demográfico de 2022 e do agregado por setores censitários. Detalhamentos do tratamento dos dados e da construção do Cadastro Mestre foram aprofundados nas seções 3.3 e 3.4.

As variáveis de interesse selecionadas para a apresentação dos resultados nos planos amostrais apresentados neste capítulo foram escolhidas de forma arbitrária de acordo com a disponibilidade dos dados no agregado por setores censitários no momento da elaboração desta monografia. Estas são:

- Domicílios Particulares Permanentes Ocupados que utilizam rede geral de distribuição;
- Domicílios Particulares Permanentes Ocupados que possuem água encanada na casa, tipo de espécie é casa;
- Domicílios Particulares Permanentes Ocupados que possuem esgoto ligado à rede geral ou pluvial;
- Domicílios Particulares Permanentes Ocupados que possuem fossa séptica não ligada à rede;
- Domicílios Particulares Permanentes Ocupados que o lixo é coletado por serviço de limpeza;
- Domicílios Particulares Permanentes Ocupados que o lixo é queimado na propriedade.

O Quadro 1 da Seção 3.3 apresenta quais variáveis representam essas informações e os respectivos arquivos em que podem ser encontradas. Os métodos descritos ao longo deste trabalho podem ser replicados para outras variáveis do agregado por setores censitários de forma análoga, desde que sejam variáveis indicadoras em nível de DPPOs.

Nos arquivos de agregados por setores censitários, cada linha da base representa um setor. Para obter os valores por UPA, os setores pertencentes à mesma UPA foram agregados por soma. Por exemplo, se uma UPA é composta por dois setores cujos valores da variável de interesse são 100 e 20, o valor agregado no Cadastro Mestre para a UPA será 120. Além disso, os valores suprimidos pelo IBGE foram imputados por meio do método *hot-deck*, utilizando como variáveis de domínio o município e as variáveis que compõem o estrato geográfico. Todo esse processo de tratamento das variáveis de interesse está descrito na seção 3.4.1.

O cadastro utilizado conta com $M = 5.851$ UPAs, $N = 1.303.003$ domicílios e 3.522.395 moradores, e abrange a capital Curitiba e os 28 municípios da região metropolitana de Curitiba, no estado do Paraná. O cadastro de UPAs é dividido em 15 estratos, o número de domicílios por estrato (N_h) e o número de UPAs por estrato (M_h) podem ser visualizados na Tabela 1 presente no capítulo 3.

O tamanho da amostra (m) é de 385 UPAs. Inicialmente, o número previsto era de 384 UPAs, seguindo o valor utilizado pela amostra mestra em aplicações anteriores. No entanto, devido a questões de arredondamento durante o processo de alocação das UPAs entre os estratos, o total final resultou em 385 UPAs. A Tabela 4 exibe a quantidade de UPAs estão na população e na amostra em cada estrato.

Tabela 4 – Quantidade de UPAs por estrato h

Estrato (h)	Nº total de UPAs (M_h)	UPAs na amostra (m_h)
1	234	11
2	546	25
3	630	29
4	554	26
5	550	26
6	573	27
7	272	27
8	439	43
9	374	37
10	437	43
11	381	37
12	382	37
13	161	6
14	165	6
15	153	5

Fonte: Agregados por setores censitários (IBGE, 2025).

5.2 Cálculo dos parâmetros populacionais

A Tabela 5 mostra os valores populacionais para as variáveis de interesse, bem como sua proporção em relação ao total de domicílios.

Tabela 5 – Parâmetros populacionais das variáveis de interesse

Variável de Interesse	Notação	Valor
Total de domicílios que utilizam a rede geral de distribuição	Y_1	1.218.933
Total de domicílios com água encanada na casa, onde o tipo de espécie é casa	Y_2	965.986
Total de domicílios onde esgoto ligado à rede geral ou pluvial	Y_3	1.104.397
Total de domicílios onde há fossa séptica não ligada à rede	Y_4	98.946
Total de domicílios onde o lixo é coletado por serviço de limpeza	Y_5	1.215.426
Total de domicílios onde o lixo é queimado na propriedade	Y_6	15.371
Proporção de domicílios que utilizam a rede geral de distribuição	p_1	93,5%
Proporção de domicílios com água encanada na casa, onde o tipo de espécie é casa	p_2	74,1%
Proporção de domicílios onde esgoto ligado à rede geral ou pluvial	p_3	84,8%
Proporção de domicílios com fossa séptica não ligada à rede	p_4	7,6%
Proporção de domicílios com lixo coletado por serviço de limpeza	p_5	93,3%
Proporção de domicílios com lixo queimado na propriedade	p_6	1,2%

Fonte: Agregados por setores censitários (IBGE, 2025).

As proporções são calculadas dividindo os totais populacionais por N , conforme a equação 4.6. A tabela revela uma alta proporção de domicílios que utilizam a rede geral de distribuição de água e de domicílios cujo lixo é coletado por serviço de limpeza, ambas acima de 90%. Aproximadamente 1,22 milhão de domicílios utilizam a rede geral de distribuição, e cerca de 1,21 milhão têm o lixo coletado por serviço de limpeza.

Observa-se também uma elevada proporção de domicílios com esgoto ligado à rede geral ou pluvial, representando 84,8% — ou cerca de 1,1 milhão de domicílios. Entre os que não possuem ligação à rede de esgoto, 7,6% (por volta de 99 mil domicílios) da capital e da região metropolitana de Curitiba utilizam fossa séptica não conectada à rede geral. Já entre os que não têm o lixo coletado por serviço de limpeza, 1,2% ou aproximadamente 15 mil domicílios queimam o lixo em suas propriedades.

5.3 Seleção das UPAs por PPT de Pareto

Nesta etapa, procede-se à seleção das Unidades Primárias de Amostragem (UPAs) com probabilidade proporcional ao tamanho (PPT), utilizando o algoritmo de Pareto,

conforme a metodologia descrita na Seção 4.2.5 e em Freitas e Antonaci (2014).

Apesar de não ser necessário selecionar uma amostra para o cálculo da variância, optou-se por realizar replicações da Amostra Mestre e calcular o erro quadrático médio (EQM), além da própria variância. Essa escolha se justifica pela inexistência de um estimador não viciado da variância para o método PPT-PCE, permitindo, assim, comparações mais equivalentes com o EQM obtido por esse método.

Nessa seleção, utiliza-se o método PPT de Pareto — o mesmo adotado para a Amostra Mestre —, o qual garante que a probabilidade de inclusão de cada UPA seja proporcional ao seu tamanho, medido em domicílios particulares permanentes ocupados (DPPOs).

Inicialmente, adicionou-se ao cadastro de UPAs a informação referente ao número de unidades a serem selecionadas em cada estrato final (m_h), vista anteriormente na Tabela 4, que é calculado de forma proporcional ao número de UPAs em cada estrato estatístico e também mantendo a proporção de cada estrato geográfico na amostra final da Amostra Mestre em vigor. A Expressão que descreve essa operação está em 4.1.

Em seguida, conforme o procedimento descrito em Freitas e Antonaci (2014), para cada UPA sorteou-se um número aleatório contínuo entre 0 e 1, denominado A_i . Tal número foi gerado com distribuição uniforme de maneira independente para cada UPA, utilizando a função `runif()` da linguagem R.

A seguir, calculou-se para cada UPA a probabilidade de inclusão desejável da mesma, onde esta se dá pela proporção de DPPOs na UPA em relação à quantidade de DPPOs por estratos, multiplicado pelo número de unidades a serem incluídas na amostra naquele estrato, conforme descrito na equação 4.7.

Com as probabilidades de inclusão calculadas, procedeu-se à geração de um número aleatório modificado C_{hi} para cada UPA, segundo a fórmula:

$$C_{hi} = \frac{A_{hi} - A_{hi} \times \pi_{hi}}{\pi_{hi} - A_{hi} \times \pi_{hi}}$$

As UPAs foram, então, ordenadas em ordem crescente dos valores de C_{hi} dentro de cada estrato final. A seleção da amostra foi realizada tomando-se as primeiras m_h UPAs dessa ordenação, sendo m_h o número de UPAs a serem selecionadas em cada estrato, conforme definido no plano de alocação.

Como se trata de uma amostra estratificada, o processo descrito acima foi repetido separadamente para cada estrato, utilizando-se um *loop*. Ao final de cada iteração, foi estimado o valor de $\hat{Y}_h$ por meio da Expressão 4.8. Após obter as estimativas de $\hat{Y}_h$ para os 15 estratos, obteve-se $\hat{Y}$ pela soma das estimativas de cada estrato. A proporção $\hat{p}$ foi estimada com base na Expressão 4.9, considerando o tamanho populacional N como

conhecido. Replicou-se o mesmo processo 1000 vezes, assim resultando em mil estimativas de $\hat{p}$. Para garantir a consistência no desenvolvimento desta monografia, inicialmente foi utilizada uma semente aleatória (*seed*) inicial com o valor 123 e, em cada nova simulação $K = \{1...1000\}$, era atualizada com $123 + K$, assim garantindo que se sorteassem as mesmas 1000 amostras.

5.4 Resultados da simulação e cálculo da variância

O erro quadrático médio do estimador de proporção $\hat{p}$ foi utilizado como medida de precisão nos resultados da simulação, observando a diferença do valor real de p e o estimado, calculou-se também o coeficiente de variação com a Expressão 4.14, como medida de precisão relativa. O tempo médio para a simulação das amostras e cálculos das estimativas, incluindo os CVs para cada variável de interesse, foi de 2 minutos e 10 segundos aproximadamente.

O equipamento utilizado para realizar as simulações foi um computador com sistema operacional *Windows 10 Home Single Language*, processador *Intel Core i7-7500U CPU @ 2.70GHz*, com 8 GB de memória RAM e SSD de 225 GB. O sistema é de 64 bits e não conta com aceleração gráfica dedicada.

Uma vez que há acesso a um cadastro e todas as variáveis necessárias para o cálculo da variância teórica são conhecidas, é possível calcular a variância do estimador sem sortear uma amostra para verificar a eficiência do plano amostral da Amostra Mestre com PPT de Pareto.

Para obter $Var(\hat{p})$, utilizamos a Expressão 4.13. Para calcular $\sum_{h=1}^H Var(\hat{Y})$, foi necessário utilizar a Expressão 4.10. Foi também calculado o CV, de acordo com a equação 4.18, como forma de avaliar a precisão relativa das estimativas dos parâmetros.

Os resultados da Tabela 6 indicam que ao se utilizar o Plano Amostral com PPT de Pareto, há baixa variabilidade na estimativa da proporção de domicílios em que o lixo é queimado na propriedade. Em contraste, “DPPOs que o tipo de espécie é casa e possuem água encanada na casa” tiveram a maior variabilidade dentre as variáveis de interesse comparadas.

Tabela 6 – Comparação entre a variância teórica e resultados das simulações para diferentes variáveis

Variável	Var($\hat{p}$) $\times 10^6$	EQM($\hat{p}$) $\times 10^6$	Viés Relativo	CV($\hat{p}$)	
				(1)	(2)
DPPOs que utilizam a rede geral de distribuição	44,4	46,9	-0,1‰	0,7%	0,7%
DPPOs que possuem água encanada na casa, tipo de espécie é casa;	277,0	279,1	-0,3 ‰	2,3%	2,2%
DPPOs que possuem esgoto ligado à rede geral ou pluvial	79,8	79,8	-0,1 ‰	1,1%	1,1%
DPPOs que possuem fossa séptica não ligada	62,7	66,8	-3,0 ‰	10,8%	10,4%
DPPOs que o lixo é coletado por serviço de limpeza	71,6	72,3	0,1 ‰	0,9%	0,9%
DPPOs que o lixo é queimado na propriedade	10,1	11,0	-1,2 ‰	28,1%	26,9%

Fonte: Agregados por setores censitários (IBGE, 2025).

Notas: (1) Simulação e (2) PPT-Pareto.

A variável “DPPOs que o lixo é queimado na propriedade” possui o menor erro quadrático médio, ou seja, é a variável onde a média dos desvios quadráticos entre o valor real de p e os estimados são menores; também é a variável com menor variância dentre as comparadas. No entanto, como é uma proporção bem pequena na população, é esperado que os seus desvios da média também sejam pequenos, também teve o segundo maior viés relativo entre as variáveis comparadas, sendo este de -1,2‰. Por outro lado, variável “DPPOs que possuem água encanada na casa, tipo de espécie é casa” possui a maior variância e erro quadrático médio das variáveis avaliadas, sendo então a variável que produziu maior diferença, em média, das estimativas em relação ao parâmetro populacional.

As diferenças das estimativas pela variância e erro quadrático médio foram pequenas no geral. No entanto, foram mais acentuadas nas variáveis “DPPOs que possuem fossa séptica não ligada”. Isso pode ser explicado porque essa variável possui o maior viés relativo de $\hat{p}$, dentre todas as comparadas. Nota-se também que a variável “DPPOs que possuem esgoto ligado à rede geral ou pluvial” não teve diferença significativa entre a variância calculada e o EQM das simulações.

De forma geral, quanto menor o CV, maior a precisão da estimativa — sendo, portanto, desejável que esse valor seja o menor possível. O Quadro 3, extraído de (IBGE, 2016) mostra um critério objetivo para avaliar o CV a partir do intervalo em que se encontra.

As estimativas de proporção para as variáveis “DPPOs que utilizam a rede geral de distribuição”, “DPPOs que possuem água encanada na casa, tipo de espécie é casa”,

“DPPOs que possuem esgoto ligado à rede geral ou pluvial” e “DPPOs que o lixo é coletado por serviço de limpeza” podem ser classificadas como ótimas tanto utilizando o EQM quanto a variância, de acordo com o critério de avaliação baseado no coeficiente de variação (CV). Essas variáveis apresentam valores absolutos elevados na população, o que tende a resultar em menor variabilidade relativa nas estimativas.

Quadro 3 – Classificação das estimativas quanto à precisão

Indicador	Intervalo do coeficiente de variação - CV (%)	Conceito
Z	Zero	Exata
A	Até 5	Ótima
B	Mais de 5 a 15	Boa
C	Mais de 15 a 30	Razoável
D	Mais de 30 a 50	Pouco precisa
E	Mais de 50	Imprecisa

Fonte: Diretoria de Pesquisas, IBGE.

A estimativa da proporção de DPPOs que possuem fossa séptica não ligada à rede geral apresenta um CV de aproximadamente 10,8% quando calculado utilizando o EQM e 10,4% quando utiliza-se a variância, estando assim na faixa que pode ser classificada como uma boa estimativa em ambos os casos. Já a proporção de “DPPOs que o lixo é queimado na propriedade” é estimada com um CV de 28,1% com o EQM e 26,9% com a variância, indicando precisão apenas razoável, porém ao estimar valores cuja incidência é próxima de zero é comum o CV ser maior e isso é da natureza da medida e não necessariamente significa que a estimativa seja ruim.

5.5 Aplicação da metodologia alternativa

A metodologia alternativa adotada consiste em empregar o algoritmo de Probabilidades Proporcionais ao Tamanho (PPT) de Poisson Correlacionado Espacialmente em substituição ao PPT de Pareto para a seleção da Amostra Mestra. A aplicação desse método foi realizada por meio da função `scps` do pacote `BalancedSampling` no ambiente R ([Grafström; Prentius; Lisic, 2025](#)).

A função `scps` foi desenvolvida para selecionar amostras espacialmente balanceadas com probabilidades de inclusão pré-definidas de uma população finita, utilizando o PPT de Poisson Correlacionado Espacialmente ([Grafström; Prentius; Lisic, 2025](#)). Este método requer, como entrada, um vetor de probabilidades de inclusão (π_{hi}) e uma matriz auxiliar X . A dimensão da matriz X corresponde ao número de unidades no cadastro (linhas) e a um conjunto de variáveis quantitativas padronizadas (colunas) associadas a cada unidade da população ([Grafström; Prentius; Lisic, 2025](#)). A matriz X é fundamental para incorporar informações geográficas à amostra, utilizando a distância euclidiana ao quadrado.

Neste trabalho, X possui dimensão $(M_h \times 3)$, englobando as coordenadas geográficas das UPAs e suas respectivas probabilidades de seleção. A função `scps` foi aplicada de forma independente em cada um dos estratos, pois não possui suporte à estratificação. Logo, para garantir a integridade das estimativas durante o desenvolvimento desta monografia, em cada iteração k , onde sorteavam-se 15 amostras (uma para cada estrato), definiu-se uma semente aleatória (*seed*).

Para esta estratégia, empregou-se o mesmo conjunto de dados e o mesmo tratamento utilizado na seleção da amostra por PPT de Pareto. O tamanho da amostra também foi mantido idêntico, resultando na seleção de $m = 385$ UPAs.

5.5.1 Probabilidade de inclusão

A probabilidade de inclusão considerada neste estudo é a mesma adotada no método de Pareto com Probabilidades Proporcionais ao Tamanho (PPT) e é definida pela Expressão 4.7.

5.5.2 Matriz auxiliar

A matriz auxiliar serve como o instrumento principal para incorporar informações geográficas ao plano amostral. Neste trabalho, a informação geográfica foi extraída da malha de setores censitários e processada no software R, utilizando o pacote `sf` (Pebesma et al., 2025).


Inicialmente dentro do arquivo da malha de setores, a informação geométrica dos setores censitários é representada por polígonos que delimitam suas respectivas áreas geográficas e manteve-se como polígono ao agregar setores em UPAs, sendo que se uma UPA tinha mais de um setor, agregava-se as geometrias dos setores por uma operação de união, utilizando a função `st_union` do pacote `sf`. Para a construção da matriz auxiliar, era necessário o uso de uma informação geográfica numérica para compor as colunas da matriz auxiliar X , por isso, por intermédio do pacote `sf` obteve-se o centroide de cada polígono, transformando-o em uma representação pontual da localização do setor. A partir desses centroides, foram extraídas as coordenadas geográficas (latitude e longitude), que são usadas diretamente na construção da matriz.

A Figura 8 exibe as geometrias de algumas UPAs do Cadastro Mestre. Caso fossem representadas graficamente todas as UPAs em conjunto, teria-se a representação espacial completa do Cadastro Mestre. Além das geometrias, a figura mostra os centróides (em vermelho) e suas respectivas coordenadas geográficas X e Y , que compõem a matriz auxiliar de informações geométricas.


A terceira coluna da matriz é composta por um vetor contendo as probabilidades de inclusão das Unidades Primárias de Amostragem (UPAs). Embora o algoritmo suporte

Figura 8 – Algumas UPAs, sua respectiva geometria (polígono) e centroides representados individualmente

UPA 4106902-1-01398




UPA 4106902-2-00097



UPA 4106902-1-02721



UPA 4119509-4-00079



Fonte: Elaborado pela autora com base nas informações da malha de setores censitários (IBGE, 2024).

o uso exclusivo das coordenadas geográficas, a inclusão de uma variável auxiliar adicional, como a própria probabilidade de inclusão, é recomendada para enriquecer a estrutura da matriz e potencialmente otimizar o desempenho do método (Grafström, 2012).

A última etapa para construir a matriz auxiliar é padronizar suas colunas utilizando o comando `scale` do R. Essa padronização é necessária para o uso dos pesos maximais e constitui um requisito da função `scps`, do pacote `BalancedSampling`. A transformação garante que todas as variáveis da matriz possuam a mesma ordem de grandeza, assegurando que contribuam equitativamente no processo de seleção amostral (Grafström, 2012).

A matriz 5.1 exibe um trecho da matriz auxiliar X_h utilizada para a seleção por PPT-PCE. Nessa matriz de dimensão $M_h \times 3$, no caso 161×3 a primeira coluna representa o valor padronizado da coordenada geográfica X da latitude da i -ésima UPA do estrato h , a segunda coluna representa o valor padronizado da coordenada geográfica Y da longitude

da mesma UPA, e a terceira o valor padronizado da probabilidade de inclusão π_{hi} .

$$\mathbf{X}_h = \begin{bmatrix} 1,3708 & 1,8567 & -0,5840 \\ 1,4510 & 1,8747 & 0,0220 \\ 1,1364 & 1,4991 & 0,5774 \\ 0,0662 & -1,3263 & 0,4259 \\ 0,0363 & -1,2625 & 0,9309 \\ -0,3184 & -0,5790 & -1,4930 \\ -0,9079 & -0,0891 & -0,5840 \\ -1,3759 & -0,2306 & 1,5369 \\ -1,1244 & -0,1592 & 1,2844 \\ \vdots & \vdots & \vdots \\ u_{hi} & v_{hi} & w_{hi} \end{bmatrix} \quad (5.1)$$

5.5.3 Seleção da amostra por PPT de Poisson Correlacionado Espacialmente

Como o plano amostral inclui estratificação, foi selecionada uma amostra para cada estrato h de forma independente e calculado o valor de $\hat{Y}_h$. Ou seja, em cada estrato $h \in H$ aplicou-se a função `scps` para as probabilidades de inclusão e matriz auxiliar formada pelas probabilidades de inclusão e coordenadas de latitude e longitude dos centroides padronizadas.

A função retorna os índices do Cadastro Mestre das unidades selecionadas, ou seja: se a função retornar 1, a primeira unidade foi selecionada para a amostra, se retornar 32, a 32ª unidade foi selecionada para a amostra, etc. Com os Y_{hi} das unidades selecionadas, estimou-se o total populacional com base na Expressão 4.8 para cada uma das amostras selecionadas.

Analogamente às simulações realizadas com o método PPT de Pareto, como a amostragem utilizada é estratificada, o processo de estimação foi conduzido separadamente para cada um dos 15 estratos. Para isso, implementou-se um algoritmo que, em cada iteração, estimava o valor de $\hat{Y}_h$ utilizando a Expressão 4.8. Em seguida, as estimativas por estrato foram agregadas para obtenção da estimativa total $\hat{Y}$ (por soma) e da proporção populacional $\hat{p}$, conforme a Expressão 4.9, assumindo o tamanho total da população N como conhecido.

Esse procedimento foi repetido 1000 vezes, resultando em mil estimativas da proporção $\hat{p}$. O processo foi aplicado para cada uma das seis variáveis de interesse. É importante destacar que, a cada vez que o programa era executado para uma nova variável, todo o código era rodado novamente desde o início. No entanto, como as sementes aleatórias eram reinicializadas com o mesmo valor ($123 + k$, onde o k era a ordem da iteração), as mesmas 1000 amostras eram sempre sorteadas, garantindo comparabilidade entre os resultados.

Os códigos que implementam esse processo estão disponíveis no Apêndice C.

5.5.4 Resultados da simulação

Foram sorteadas $K = 1000$ amostras utilizando PPT de Poisson Correlacionado Espacialmente. Os estimadores de total e de proporção utilizados são os mesmos das Expressões 4.5 e 4.9 e o erro quadrático médio (EQM) pode ser estimado pela Expressão em 4.14 e o coeficiente de variação pode ser estimado pela fórmula em 4.19. Para cada variável de interesse, o tempo médio de execução desde o momento do sorteio ao cálculo dos coeficientes de variação foi de 3 minutos e 20 segundos.

A Tabela 7 exhibe os resultados encontrados para a estratégia do plano amostral utilizando PPT de Poisson correlacionado espacialmente.

Tabela 7 – Estimativas pontuais e medidas de precisão para diferentes variáveis de interesse

Variável	$EQM(\hat{p}) \times 10^6$	Viés relativo	$CV_{\hat{p}}$
DPPOs que utilizam a rede geral de distribuição	42,1	40,6 ‰	0,7%
DPPOs que possuem água encanada na casa, tipo de espécie é casa	184,6	1,6 ‰	1,8%
DPPOs que possuem esgoto ligado à rede geral ou pluvial	68,6	3,9 ‰	1,0%
DPPOs que possuem fossa séptica não ligada	56,5	-0,4 ‰	9,9%
DPPOs que o lixo é coletado por serviço de limpeza	60,9	-17,6‰	0,8%
DPPOs que o lixo é queimado na propriedade	8,1	0,4 ‰	24,1%

Fonte: Agregado por setores censitários (IBGE, 2025). Elaborado pela autora.

As estimativas de proporção dos DPPOs que utilizam a rede geral de distribuição, DPPOs cujo lixo é coletado por serviço de limpeza, DPPOs que possuem água encanada na casa em domicílios classificados como casa e DPPOs que possuem esgoto ligado à rede geral ou pluvial podem ser classificadas como ótimas, de acordo com os critérios apresentados na tabela. Já a estimativa referente aos DPPOs que possuem fossa séptica não ligada à rede é considerada boa, enquanto a estimativa para aos DPPOs cujo lixo é queimado na propriedade é classificada como razoável. As duas últimas variáveis apresentam baixa incidência na população, o que contribui para um coeficiente de variação (CV) naturalmente mais elevado ao se estimar proporções muito pequenas. Ainda assim, ambas as estimativas mantêm uma precisão considerada satisfatória nesse contexto.

A proporção de DPPOs cujo lixo é queimado na propriedade apresentou um erro quadrático médio (EQM) particularmente baixo, o que, à primeira vista, poderia sugerir

boa qualidade da estimativa. No entanto, novamente, por ser uma proporção bem baixa na população, é natural que as diferenças entre os valores estimados e os valores do parâmetro sejam baixas, produzindo, naturalmente, um EQM baixo.

5.6 Comparação entre os planos amostrais

A Tabela 8 resume os valores dos CVs para ambas as estratégias de amostragem, permitindo uma comparação direta do desempenho de cada plano amostral:

Tabela 8 – Comparação dos coeficientes de variação para diferentes métodos de amostragem - $CV(\hat{p})$

Variável	PPT Pareto (1)	PPT Pareto (2)	PPT-PCE
DPPOs que utilizam a rede geral de distribuição	0,7%	0,7%	0,7%
DPPOs que possuem água encaçada na casa, tipo de espécie é casa	2,2%	2,3%	1,8%
DPPOs que possuem esgoto ligado à rede geral ou pluvial	1,1%	1,1%	1,0%
DPPOs que possuem fossa séptica não ligada	10,4%	10,8%	9,9%
DPPOs que o lixo é coletado por serviço de limpeza	0,9%	0,9%	0,8%
DPPOs que o lixo é queimado na propriedade	26,9%	28,1%	24,1%

Fonte: Agregados por setores censitários (IBGE, 2025).

Notas: (1) PPT-Pareto, (2) Simulações.

O coeficiente de variação (CV) do PPT de Pareto, calculado a partir do erro quadrático médio (EQM), é ligeiramente maior do que aquele obtido ao se calcular a variância — o que é esperado, já que o EQM incorpora o viés. No entanto, para as variáveis DPPOs que utilizam a rede geral de distribuição, DPPOs que têm o lixo coletado por serviço de limpeza e DPPOs que possuem esgoto ligado à rede geral ou pluvial, não houve diferença entre os métodos, considerando uma precisão de uma casa decimal nas estimativas. Coincidentemente (ou não), essas variáveis correspondem a proporções bastante altas na população.

Com exceção da estimativa para a proporção de DPPOs que utilizam a rede geral de distribuição — onde não se observou diferença entre os métodos ao nível de uma casa decimal —, nas demais variáveis de interesse, o coeficiente de variação obtido com a estratégia baseada no PPT de Poisson Correlacionado Espacialmente (PPT-PCE) foi inferior ao da abordagem tradicional com o PPT de Pareto. Isso indica uma melhora na

eficiência das estimativas quando se incorpora a informação espacial no processo de seleção amostral, pois, com o mesmo tamanho de amostra, obtém-se menor variabilidade.

Embora as melhorias nos CVs sejam discretas para a maioria das variáveis — sendo, por exemplo, de 0,1% para DPPOs que possuem esgoto ligado à rede geral ou pluvial e DPPOs que têm o lixo coletado por serviço de limpeza —, destaca-se a variável lixo queimado na propriedade, cuja diferença nos CV usando PPT-PCE alcança 4 pontos percentuais quando comparado com o EQM das simulações.

Esses resultados permitem concluir que a utilização de um plano amostral que considera a estrutura espacial das unidades, como o PPT-PCE, pode ser vantajosa quando se busca melhorar a precisão sem aumentar o tamanho da amostra. Apesar disso, a inexistência de um estimador não viesado para a variância, além do maior tempo necessário para as estimativas, coloca o método em desvantagem em relação ao PPT de Pareto. Ainda assim, a simplicidade de implementação por meio da função `scps` no R o torna uma alternativa eficiente para o sorteio da Amostra Mestra.

6 CONSIDERAÇÕES FINAIS

Esta monografia teve como objetivo analisar os efeitos da integração de coordenadas geográficas no plano amostral da Amostra Mestra no que diz respeito à eficiência. Para isso, decidiu-se por usar a metodologia do PPT de Poisson Correlacionado Espacialmente (PPT-PCE) para integrar as coordenadas geográficas. A partir da adaptação do processo de construção da Amostra Mestra do IBGE, foi estruturado um Cadastro Mestre com base nos setores censitários do estado da Região Metropolitana de Curitiba, o que permitiu a simulação, a comparação dos métodos, além dos cálculos da variância, erro quadrático médio e coeficiente de variação de seis estimadores diferentes de parâmetros populacionais como medidas de eficiência.

Os resultados obtidos indicam que o método PPT-PCE apresentou coeficiente de variação (CV) menor ou igual ao método PPT de Pareto (PPT-Pareto) atualmente utilizado na Amostra Mestra pelo IBGE para os estimadores de todas as variáveis analisadas, sugerindo que há aumento na eficiência na estimação de proporções quando comparado ao PPT-Pareto.

Essa constatação responde à pergunta de pesquisa proposta nesta monografia. No entanto, é importante destacar que a diferença entre os CVs foi pequena, e não foi avaliada se essa diferença é estatisticamente significativa.

Apesar da vantagem observada em termos de precisão, o método PPT-PCE apresentou desvantagens importantes. A principal limitação refere-se à não existência de um estimador não viesado para a variância de estimativas sob esse método. Isso exigiu a realização de múltiplas replicações. O tempo médio para gerar as estimativas de uma variável de interesse usando o PPT-PCE foi de pouco mais de 3 minutos, enquanto com o PPT-Pareto, as mesmas simulações demoraram 2 minutos e 10 aproximadamente, utilizando operações vetoriais com o pacote `dplyr`, o tempo foi de cerca de 2 segundos — embora parte dessa diferença possa ser atribuída à forma como o código foi implementado (com estruturas de repetição do tipo `for`).

Outro aspecto relevante é a limitação da função `SCPS` quanto à escolha da estratégia de pesos. A única opção disponível é o uso de pesos maximais baseados em distância euclidiana, o que pode não ser apropriado em regiões extensas, pois essa métrica não leva em consideração a curvatura da Terra. Em áreas maiores, como em aplicações a nível nacional, o uso dessa estratégia pode comprometer a validade dos resultados. Seria desejável a avaliação de outras métricas de distância, como distâncias geodésicas para áreas maiores e avaliação de outros pesos de forma geral. O artigo [Grafström \(2012\)](#) exemplifica o método com pesos maximais e pesos gaussianos; no entanto, os resultados

(ambos com distância euclidiana) mostram que a estratégia de pesos maximais apresentou uma eficiência maior.

Além disso, o balanceamento espacial da amostra — frequentemente citado como uma das principais vantagens do método PPT-PCE — não foi incorporado como critério de avaliação nesta monografia. O texto [Favre-Martinoz et al. \(2018.\)](#) recomenda o uso do Índice de Voronoi para mensurar o grau de dispersão das amostras, o que pode ser considerado em trabalhos futuros.

Em resumo, esta monografia mostrou que o método PPT-PCE tende a produzir estimativas precisas, e um discreto aumento de eficiência em relação ao PPT de Pareto no contexto analisado, mas apresenta limitações operacionais e computacionais que devem ser consideradas. Em aplicações maiores ou em regiões com topografia complexa, a escolha do método e da métrica de distância devem ser cuidadosamente avaliados. Trabalhos futuros podem explorar formas alternativas de balanceamento espacial, diferentes estratégias de pesos e métricas geográficas mais adequadas para contextos variados.

REFERÊNCIAS

- Agência de Assuntos Metropolitanos do Paraná. *Municípios da Região Metropolitana de Curitiba*. 2025. Acesso em: 27 abr. 2025. Disponível em: <<https://www.amep.pr.gov.br/FAQ/Municipios-da-Regiao-Metropolitana-de-Curitiba>>. Citado 3 vezes nas páginas 29, 32 e 33.
- Arantes, S. B. *Planejamento De Amostras Domiciliares No Brasil Explorando a Malha Setorial Do Censo Demográfico 2010*. Dissertação (Dissertação de Mestrado) — Escola Nacional de Ciências Estatísticas (ENCE), Rio de Janeiro, Brasil, 2012. Citado 3 vezes nas páginas 16, 45 e 51.
- Arantes, S. B.; Silva, P. L. d. N. Planejamento de amostras domiciliares no brasil explorando a malha setorial do censo demográfico 2010. *Revista brasileira de estatística*, v. 74, n. 239, p. 101–130, 2013. Citado 2 vezes nas páginas 11 e 44.
- Bianchini, Z. M.; Albieri, S. Principais aspectos da amostragem das pesquisas domiciliares do ibge: revisão 2002. *Rio de Janeiro: IBGE*, 2003. Citado na página 16.
- Brito, J. A. de M. Documentos para disseminação: Memória institucional 22. In: _____. Rio de Janeiro: IBGE, 2017. cap. Método de otimização aplicado à estratificação de unidades primárias de amostragem, p. Page Range. Citado na página 34.
- Carletto, C. et al. Positioning household surveys for the next decade. *Statistical Journal of the IAOS*, IOS Press, v. 38, n. 4, p. 923–946, 2022. Citado na página 17.
- Cochran, W. G. Sampling techniques. *Johan Wiley & Sons Inc*, 1977. Citado 4 vezes nas páginas 39, 41, 49 e 50.
- Comissão de Estatística da Organização das Nações Unidas. *Fundamental Principles of Official Statistics*. 1994. Citado na página 10.
- Departamento Administrativo Nacional de Estadística (DANE). *METODOLOGIA GERAL GRAN ENCUESTA INTEGRADA DE HOGARES GEIH*. 2016. Documento metodológico. Citado na página 17.
- Favre-Martinoz, C. et al. Spatial sampling. In: *Handbook of Spatial Analysis: Theory and Practical Application with R*. INSEE, 2018. cap. 10. Disponível em: <<https://www.insee.fr/en/statistiques/fichier/3635545/imet131-n-chapitre-10.pdf>>. Citado 4 vezes nas páginas 11, 12, 18 e 68.
- Freitas, M. P. S. de; Antonaci, G. de A. *Sistema Integrado de Pesquisas Domiciliares: Amostra Mestra 2010 e Amostra da PNAD Contínua - Texto de Discussão nº 50*. 2014. Citado 12 vezes nas páginas 11, 20, 21, 22, 23, 25, 26, 29, 32, 36, 37 e 57.
- Grafström, A. Spatially correlated poisson sampling. *Journal of Statistical Planning and Inference*, v. 142, p. 139–147, 1 2012. ISSN 03783758. Citado 9 vezes nas páginas 12, 18, 46, 47, 48, 51, 52, 62 e 67.

- Grafström, A.; Prentius, W.; Lisic, J. *BalancedSampling: Balanced Sampling*. [S.l.], 2025. R package version 1.4.1. Disponível em: <<https://cran.r-project.org/web/packages/BalancedSampling/BalancedSampling.pdf>>. Citado 2 vezes nas páginas 48 e 60.
- IBGE. *Sistema Integrado de Pesquisas Domiciliares – SIPD - Texto de Discussão nº 24*. 2007. Citado 4 vezes nas páginas 11, 20, 23 e 24.
- IBGE. *Guia para a divulgação de erros amostrais associados às estimativas provenientes de pesquisas por amostragem probabilística, realizadas pelo IBGE*. Rio de Janeiro: [s.n.], 2016. Documento interno. Citado na página 59.
- IBGE - Instituto Brasileiro de Geografia e Estatística. *Atlas geográfico escolar - IBGE*. 2025. Acesso em 11 de julho de 2025. Disponível em: <<https://atlasescolar.ibge.gov.br/glossario/colar-metropolitano.html>>. Citado na página 23.
- Instituto Brasileiro de Geografia e Estatística - IBGE. *Código de Boas Práticas das Estatísticas do IBGE*. Rio de Janeiro: IBGE, 2013. Disponível em: <https://ftp.ibge.gov.br/Informacoes_Gerais_eReferencia/Codigo_de_Boas_Praticas_das_Estatisticas_do_IBGE.pdf>. Citado na página 10.
- Instituto Brasileiro de Geografia e Estatística (IBGE). *Malha de Setores Censitários: Censo demográfico 2022*. Rio de Janeiro: IBGE, 2024. <<https://biblioteca.ibge.gov.br/visualizacao/livros/liv102138.pdf>>. (Coleção Ibgeana). Disponível somente em meio digital. Disponível em: <<https://biblioteca.ibge.gov.br/visualizacao/livros/liv102138.pdf>>. Citado na página 27.
- Lohr, S. L. *Sampling: design and analysis*. [S.l.]: Chapman and Hall/CRC, 2021. Citado 9 vezes nas páginas 39, 41, 42, 43, 44, 49, 50, 52 e 53.
- Maligalig et al. Developing a master sample design for household surveys in developing countries: A case study in bangladesh. *Survey Methods: Insights from the Field*, p. 1–25, 2013. Veröffentlichungsversion / Published Version. Disponível em: <<https://doi.org/10.13094/SMIF-2013-00009>>. Citado na página 18.
- Matei, A. et al. Targetted double control of burden in multiple surveys. *Survey Methodology*, v. 49, n. 2, p. 363–384, 2023. Citado na página 18.
- Muiños, R. *Muestra Maestra Urbana de Viviendas De La Republica Argentina MMUVRA 2011*. [S.l.], 2018. (Reunion del Grupo de Trabajo Sobre Encuestas a Hogares de la Conferencia Estadística de las Americas). Acessado em junho de 2025. Disponível em: <<https://biblioteca.indec.gob.ar/bases/minde/2mi600.pdf>>. Citado na página 17.
- Pebesma, E. et al. *sf: Simple Features for R*. Vienna, Austria, 2025. R package version 1.0-21. Disponível em: <<https://r-spatial.github.io/sf/>>. Citado na página 61.
- Pessoa, D. G. C.; Silva, P. L. N. Análise de dados amostrais complexos. *São Paulo: Associação Brasileira de Estatística*, v. 112, 1998. Citado na página 15.
- Pettersson, H. Household sample surveys in developing and transition countries: Studies in methods series f no. 96. In: _____. New York: Department of Economic and Social Affairs Statistics Division - United Nations, 2005. cap. Chapter V - Design of master sampling frames and master samples for household surveys in developing countries, p. 71–94. Citado 3 vezes nas páginas 10, 16 e 17.

Pitta, M. T.; Silva, P. L. do N.; Brito, J. A. de M. *Planejamento Amostral para Pesquisa TIC Domicílios 2025*. [S.l.], 2025. Citado 4 vezes nas páginas 30, 31, 32 e 34.

Silva, P. L. do N. *ALGUMAS IDÉIAS PARA A REVISÃO DAS PESQUISAS DOMICILIARES POR AMOSTRAGEM DO IBGE*. RIO DE JANEIRO, 2001. Texto apresentado em 10 de Agosto de 2001 [1]. Citado na página 17.

Silva, P. L. do N.; Dias, A. J. R.; Bianchini, Z. M. *Amostragem: Teoria e Prática usando R*. [S.l.: s.n.], 2021. Citado 6 vezes nas páginas 15, 16, 41, 44, 45 e 49.

Silva, P. L. do N.; Pessoa, D. G. C.; Lila, M. F. Análise estatística de dados da pnad: incorporando a estrutura do plano amostral. *Ciência & Saúde Coletiva*, ABRASCO - Associação Brasileira de Saúde Coletiva, v. 7, n. 4, p. 659–670, 2002. ISSN 1413-8123. Disponível em: <<https://doi.org/10.1590/S1413-81232002000400005>>. Citado na página 15.

Anexos

ANEXO A – CÓDIGOS CADASTRO MESTRE

```
# =====
# CONSTRUÇÃO DO CADASTRO MESTRE ESTRATIFICADO - TCC
# Análise de Dados de Amostragem Complexa
# =====

# LIMPEZA DO AMBIENTE -----
rm(list = ls())

# CARREGAMENTO DE PACOTES -----
suppressPackageStartupMessages({
  library(purrr)
  library(VIM)
  library(sf)
  library(lwgeom)
  library(tidyverse)
  library(arrow)
  library(labelled)
  library(stringr)
})

# =====
# 1. CONSTRUÇÃO DO CADASTRO MESTRE INICIAL
# =====

# Carregamento e filtragem inicial dos dados
cadastro_mestre <- readRDS("upas_pr.rds")

# Aplicação de filtros:
# - Manter apenas UPAs com mais de 60 domicílios
# - Excluir áreas do interior
cadastro_mestre <- cadastro_mestre %>%
  filter(n_domic > 60, est_geo2 != 'Interior')
```

```

# Criação da variável de estratificação geográfica
cadastro_mestre <- cadastro_mestre %>%
  mutate(
    estrato_geografico = interaction(est_geo2, est_geo3),
    estrato_geografico = as.factor(estrato_geografico),
    estrato_geografico = case_when(
      estrato_geografico == "Capital.Urbano-favela e comunidade" ~ 1,
      estrato_geografico == "Capital.Urbano-não especial" ~ 2,
      estrato_geografico == "Entorno de RM de capital.Urbano-favela e comunidade" ~ 3,
      estrato_geografico == "Entorno de RM de capital.Urbano-não especial" ~ 4,
      estrato_geografico == "Entorno de RM de capital.Rural" ~ 5
    )
  )

# Verificação da distribuição dos estratos
table(cadastro_mestre$estrato_geografico)

# =====
# 2. SEPARAÇÃO POR ESTRATOS GEOGRÁFICOS
# =====

# Criação de subconjuntos por estrato
H_1 <- subset(cadastro_mestre, estrato_geografico == 1) # Capital - Favela/Comunidade
H_2 <- subset(cadastro_mestre, estrato_geografico == 2) # Capital - Urbano não esp
H_3 <- subset(cadastro_mestre, estrato_geografico == 3) # RM - Favela/Comunidade
H_4 <- subset(cadastro_mestre, estrato_geografico == 4) # RM - Urbano não especial
H_5 <- subset(cadastro_mestre, estrato_geografico == 5) # RM - Rural

# =====
# 3. APLICAÇÃO DA ESTRATIFICAÇÃO FINAL
# =====

# Estratos 1 e 3: Não necessitam estratificação adicional
H_1 <- H_1 %>%
  mutate(
    estrato_final = as.character(1.1),
    Estratos = 1
  )

```

```
H_3 <- H_3 %>%
  mutate(
    estrato_final = as.character(3.1),
    Estratos = 1
  )

# Estrato 2: Capital urbano não especial (5 subestratos)
estrato2_estratificado <- read_delim(
  "upas estratificadas/estrato2_NE_5_.csv",
  delim = ";",
  escape_double = FALSE,
  trim_ws = TRUE
) %>%
  rename(codigo_upa = UPas) %>%
  select(codigo_upa, Estratos)

H_2 <- H_2 %>%
  left_join(estrato2_estratificado, by = "codigo_upa") %>%
  mutate(estrato_final = as.character(interaction(estrato_geografico, Estratos)))

# Estrato 4: RM urbano não especial (5 subestratos)
estrato4_estratificado <- read_delim(
  "upas estratificadas/estrato4_NE_5_.csv",
  delim = ";",
  escape_double = FALSE,
  trim_ws = TRUE
) %>%
  rename(codigo_upa = UPas) %>%
  select(codigo_upa, Estratos)

H_4 <- H_4 %>%
  left_join(estrato4_estratificado, by = "codigo_upa") %>%
  mutate(estrato_final = as.character(interaction(estrato_geografico, Estratos)))

# Estrato 5: RM rural (3 subestratos)
estrato5_estratificado <- read_delim(
  "upas estratificadas/estrato5_NE_3_.csv",
  delim = ";",
  escape_double = FALSE,
```

```
    trim_ws = TRUE
  ) %>%
    rename(codigo_upa = UPas) %>%
    select(codigo_upa, Estratos)

H_5 <- H_5 %>%
  left_join(estrato5_estratificado, by = "codigo_upa") %>%
  mutate(estrato_final = as.character(interaction(estrato_geografico, Estratos)))

# Reagrupamento do cadastro mestre
cadastro_mestre <- bind_rows(H_1, H_2, H_3, H_4, H_5)

# Verificação da estratificação final
table(cadastro_mestre$estrato_final)

# =====
# 4. DEFINIÇÃO DOS TAMANHOS AMOSTRAIS
# =====

# Criação da variável auxiliar para tamanhos amostrais
cadastro_mestre <- cadastro_mestre %>%
  mutate(est_2sit = interaction(est_geo2, situacao))

# Cálculo dos tamanhos por estrato geográfico
tam_estratos <- cadastro_mestre %>%
  group_by(est_2sit) %>%
  summarize(M_estgeo = n(), .groups = "drop")

cadastro_mestre <- left_join(cadastro_mestre, tam_estratos, by = "est_2sit")

# Definição dos tamanhos amostrais planejados
tamanhos_amostra <- tibble(
  est_2sit = c("Capital.Urbana", "Entorno de RM de capital.Urbana", "Entorno de RM
  m_estgeo = c(144, 223, 17)
)

cadastro_mestre <- left_join(cadastro_mestre, tamanhos_amostra, by = "est_2sit")

# Cálculo da distribuição proporcional por estrato final
```

```

tamanhos <- cadastro_mestre %>%
  group_by(estrato_final, estrato_geografico, M_estgeo, m_estgeo) %>%
  summarize(M_h = n(), .groups = "drop") %>%
  mutate(
    prop_upas = round(M_h / M_estgeo, 3),
    m_h = round(prop_upas * m_estgeo)
  )

# Junção das informações de tamanho amostral
tamanhos_join <- tamanhos %>%
  select(estrato_final, M_h, prop_upas, M_estgeo)

cadastro_mestre <- left_join(cadastro_mestre, tamanhos_join, by = "estrato_final")

# =====
# 5. PREPARAÇÃO DOS DADOS DOS SETORES CENSITÁRIOS
# =====

# Carregamento da malha de setores censitários
setores_original <- st_read("PR_setores_CD2022.gpkg")
names(setores_original) <- tolower(names(setores_original))

# Filtros de exclusão para áreas especiais
dados <- setores_original %>%
  filter(
    is.na(nm_aglom) | !str_detect(
      nm_aglom,
      regex(
        "Aldeia Indígena|Quartel|Base Militar|Alojamento|Acampamento|
        Embarcação|Penitenciária|Colônia Penal|Presídio|Cadeia|Asilo|
        Orfanato|Convento|Hospital|Agrovila",
        ignore_case = TRUE
      )
    )
  ) %>%
  filter(cd_sit != 9) %>% # Exclusão de massas de água
  filter(cd_tipo %in% c(0, 1, 4)) %>% # Tipos de setor válidos
  mutate(
    geom = st_make_valid(geom),

```

```
favela = ifelse(cd_tipo == 1, "Favela ou comunidade", "não especial")
)

# =====
# 6. INCORPORAÇÃO DE VARIÁVEIS SOCIOECONÔMICAS DOS SETORES
# =====

# Função auxiliar para limpeza de dados
limpar_dados_censo <- function(dados) {
  dados[dados == "X"] <- NA

  # Conversão para numérico (exceto código do setor)
  dados[, !names(dados) %in% c("cd_setor", "setor")] <-
    lapply(dados[, !names(dados) %in% c("cd_setor", "setor")],
      function(x) as.numeric(as.character(x)))

  return(dados)
}

# Carregamento e processamento: Características de domicílios 1
agregado_dom1 <- read_delim(
  "Agregados_por_setores_caracteristicas_domicilio1_BR.csv",
  delim = ";", escape_double = FALSE, trim_ws = TRUE
)
names(agregado_dom1) <- tolower(names(agregado_dom1))
agregado_dom1 <- limpar_dados_censo(agregado_dom1)

agregado_dom1 <- agregado_dom1 %>%
  mutate(cd_setor = as.character(cd_setor)) %>%
  select(cd_setor, v00001, v00005, v00007, v00071, v00083)

dados <- left_join(dados, agregado_dom1, by = "cd_setor")

# Carregamento e processamento: Características de domicílios 2
agregado_dom2 <- read_parquet(
  "Agregados_por_setores_caracteristicas_domicilio2_BR_20250417.parquet"
)
names(agregado_dom2) <- tolower(names(agregado_dom2))
agregado_dom2 <- limpar_dados_censo(agregado_dom2)
```

```
agregado_dom2 <- agregado_dom2 %>%
  mutate(cd_setor = as.character(setor)) %>%
  select(cd_setor, v00111, v00112, v00199, v00200, v00201, v00202,
         v00309, v00310, v00311, v00312, v00397, v00399, v00494)

dados <- left_join(dados, agregado_dom2, by = "cd_setor")

# Carregamento e processamento: Características de domicílios 3
agregado_dom3 <- read_parquet(
  "Agregados_por_setores_caracteristicas_domicilio3_BR_20250417.parquet"
)
names(agregado_dom3) <- tolower(names(agregado_dom3))
agregado_dom3 <- limpar_dados_censo(agregado_dom3)

agregado_dom3 <- agregado_dom3 %>%
  mutate(cd_setor = as.character(setor)) %>%
  select(cd_setor, v00552, v00556, v00557, v00558)

dados <- left_join(dados, agregado_dom3, by = "cd_setor")

# Padronização de nomes das variáveis
dados <- dados %>%
  rename(
    n_domic = v00001,
    n_crianças = v00071,
    n_10 = v00083,
    rede_distribuicao = v00111,
    utiliza_poco = v00112,
    agua_encanada = v00199,
    agua_terreno = v00200,
    sem_agua_encanada = v00201,
    agua_encanada_casa = v00202,
    rede_geral_esgoto = v00309,
    fossa_septica = v00310,
    fossa_sem_ligacao = v00311,
    fossa_rudimentar = v00312,
    servico_limpeza = v00397,
    lixo_queimado = v00399,
```

```
    possui_banheiro = v00494
  ) %>%
  select(-situacao, -cd_sit, -cd_tipo, -cd_uf, -nm_uf, -cd_mun, -nm_mun, -favela)

# =====
# 7. INTEGRAÇÃO COM DADOS DAS UPAS
# =====

# Carregamento e integração com informações das UPAs
setores_pr <- readRDS("setores_pr.rds")
setores_censo2022 <- left_join(setores_pr, dados, by = "cd_setor") %>%
  filter(est_geo2 != "Interior")

# =====
# 8. TRATAMENTO DE VALORES FALTANTES
# =====

# Definição das variáveis de interesse para imputação
vars_alvo <- c(
  "rede_distribicao", "agua_encanada_casa", "rede_geral_esgoto",
  "fossa_sem_ligacao", "servico_limpeza", "lixo_queimado"
)

# Preparação dos dados para imputação
setores_censo2022 <- setores_censo2022 %>%
  mutate(
    across(all_of(vars_alvo), ~ ifelse(.x == "X", NA, as.numeric(.x))),
    n_domic = as.numeric(n_domic)
  )

cat("Valores faltantes antes da imputação:", sum(is.na(setores_censo2022$rede_distr

# Imputação usando hot-deck
setores_censo2022 <- VIM::hotdeck(
  data = setores_censo2022,
  variable = vars_alvo,
  ord_var = "n_domic",
  domain_var = c("cd_mun", "est_geo2", "est_geo3"),
  imp_var = TRUE
```

```

)

# Função para correção de valores imputados inadequados
corrigir_imputacao <- function(dados, variaveis) {
  for (var in variaveis) {
    # Verificação de valores inadequados
    verif <- dados %>% filter(.data[[var]] > n_domic)

    if (nrow(verif) > 0) {
      cat(var, "tinha", nrow(verif), "valores inadequados\n")
    }

    # Correção: limitar ao número de domicílios
    dados <- dados %>%
      mutate(!var := pmin(.data[[var]], n_domic))
  }

  return(dados)
}

setores_censo2022 <- corrigir_imputacao(setores_censo2022, vars_alvo)
cat("Valores faltantes após imputação:", sum(is.na(setores_censo2022$rede_distribui

# =====
# 9. AGREGAÇÃO POR UPA
# =====

# Cálculo dos totais por UPA
totais_por_upa <- setores_censo2022 %>%
  group_by(codigo_upa) %>%
  summarize(
    across(all_of(vars_alvo), ~ sum(.x, na.rm = TRUE), .names = "{col}_hi"),
    .groups = "drop"
  )

# =====
# 10. CONSTRUÇÃO DO CADASTRO MESTRE FINAL
# =====

```

```

# Junção do cadastro mestre com os totais por UPA
cadastro_mestre <- cadastro_mestre %>%
  left_join(totais_por_upa, by = "codigo_upa")

# Verificação da consistência dos dados
nomes_totais <- names(totais_por_upa)[-1]
verif_inconsistencia <- cadastro_mestre %>%
  rowwise() %>%
  filter(any(c_across(all_of(nomes_totais)) > n_domic)) %>%
  ungroup()

if (nrow(verif_inconsistencia) > 0) {
  warning("Existem inconsistências nos dados agregados!")
}

# Padronização final de nomes e criação de variáveis
cadastro_mestre <- cadastro_mestre %>%
  rename(h = estrato_final, N_hi = n_domic) %>%
  mutate(
    n_hi = 14, # Tamanho da amostra de domicílios por UPA
    h = as.character(h) # Garantir que h seja character
  ) %>%
  select(-situacao, -cd_uf, -sigla_uf, -nm_uf, -cd_mun, -n_morador,
        -area, -var_est_upa, -estrato_geografico)

# =====
# 11. CÁLCULO DE PARÂMETROS POPULACIONAIS
# =====

# Totais populacionais
N <- sum(cadastro_mestre$N_hi)
nomes_vars <- gsub("_hi", "", nomes_totais)

Totais <- cadastro_mestre %>%
  summarize(
    across(all_of(nomes_totais), ~ sum(.x, na.rm = TRUE)),
    .groups = "drop"
  ) %>%
  rename_with(~ gsub("_hi", "", .x))

```

```
# Proporções populacionais (em percentual)
prop <- (Totais / N) * 100

cat("\n=== RESULTADOS FINAIS ===\n")
cat("Total de domicílios (N):", N, "\n")
cat("\nTotais populacionais:\n")
print(Totais)
cat("\nProporções populacionais (%):\n")
print(prop)

# Informações por estrato
H <- unique(cadastro_mestre$h)

# Totais de UPAs por estrato
UPAs_h <- cadastro_mestre %>%
  group_by(h) %>%
  summarize(M_h = n(), .groups = "drop") %>%
  mutate(
    m_h = case_when(
      h == "1.1" ~ 11, h == "2.1" ~ 25, h == "2.2" ~ 29, h == "2.3" ~ 26, h == "2.4" ~ 25,
      h == "2.5" ~ 27, h == "3.1" ~ 27, h == "4.1" ~ 43, h == "4.2" ~ 37, h == "4.3" ~ 37,
      h == "4.4" ~ 37, h == "4.5" ~ 37, h == "5.1" ~ 6, h == "5.2" ~ 6, h == "5.3" ~ 6,
      TRUE ~ 0 # Valor padrão para casos não especificados
    )
  )

# Total de domicílios por estrato
Nh <- cadastro_mestre %>%
  group_by(h) %>%
  summarise(N_h = sum(N_hi), .groups = "drop")

# Integração final das informações
cadastro_mestre <- cadastro_mestre %>%
  left_join(UPAs_h, by = "h") %>%
  left_join(Nh, by = "h") %>%
  mutate(
    total = "Todos",
    pi_hi = m_h * (N_hi / N_h) # Probabilidades de inclusão
```

```
) %>%  
  arrange(total, h, codigo_upa)  
  
cat("\nCadastro mestre finalizado com", nrow(cadastro_mestre), "UPAs\n")  
cat("Estrutura final do cadastro:\n")  
print(names(cadastro_mestre))  
  
# =====  
# FIM DO SCRIPT  
# =====
```

ANEXO B – CÓDIGOS RESULTADOS PPT

PARETO

```

\footnotesize
#=====
# FUNÇÃO PARA CÁLCULO DE VARIÂNCIA E COEFICIENTE DE VARIAÇÃO
# =====

# DEFINIÇÃO DA FUNÇÃO =====
var_cv_prop <- function(Y_hi_col, p, Y) {

  # Modificação do cadastro mestre com cálculos auxiliares
  cadastro_mestre_mod <- cadastro_mestre |>
    mutate(
      Y_hi = .data[[Y_hi_col]],
      p_hi = Y_hi / N_hi,
      S2_hi = N_hi * p_hi * (1 - p_hi) / (N_hi - 1),
      parcela1 = Y_hi^2 * (1 - pi_hi) / pi_hi,
      parcela3 = N_hi^2 * ((1 / n_hi) - (1 / N_hi)) * S2_hi
    )

  # Calcula resumos que precisamos por estrato
  resumos_por_estrato <- cadastro_mestre_mod |>
    group_by(total, h) |>
    summarise(M_h = mean(M_h),
              m_h = mean(m_h),
              soma_parcl1 = sum(parcela1),
              num_parcl2 = sum(Y_hi * (1 - pi_hi)),
              den_parcl2 = sum(pi_hi^2),
              soma_parcl3 = sum(parcela3)) |>
    ungroup()

  # Calcula parcelas da variância por estrato
  resumos_por_estrato <- resumos_por_estrato |>
    mutate(soma_parcl1 = M_h * soma_parcl1 / (M_h - 1),
           soma_parcl2 = M_h * (num_parcl2^2 / (m_h - den_parcl2)) / (M_h - 1)) |>

```

```

    mutate(var_y_hat_h = soma_parcl - soma_parcl2 + soma_parcl3)

# Calcula variância do total no numerador
var_numerador <- resumos_por_estrato |>
  group_by(total) |>
  summarise(var_y_hat = sum(var_y_hat_h)) |>
  ungroup()

# Calcula variância da proporção estimada e seu CV
var_prop <- var_numerador |>
  mutate(var_prop =(var_y_hat / N^2),
         cv_prop = 100 * sqrt(var_prop) / p)

# Conferindo cv do estimador do total
var_numerador <- var_numerador |>
  mutate(cv_total = 100 * sqrt(var_y_hat) / Y)

return(var_prop)
}

# APLICAÇÃO DA FUNÇÃO =====
names(Totais)
nomes <- names(totais_por_upa)[-1]

resultados <- map2(
  nomes,
  names(Totais),
  ~ var_cv_prop(.x, prop[.y], Totais[.y]))
)

names(resultados) <- nomes # nomeia a lista com os nomes do vetor 'nomes'

# RESULTADOS =====
resultados
Totais
prop * 100

end = Sys.time()
end - start

```

```
=====
SIMULAÇÃO
=====
```

```
# escolher qual variavel
```

```
#"rede_distribuicao"
```

```
#"agua_encanada_casa" "rede_geral_esgoto" "fossa_sem_ligacao" "servico_limpeza"
```

```
#[9] "lixo_queimado"
```

```
cadastro_mestre <- cadastro_mestre %>%
```

```
  mutate(Y_hi = agua_encanada_casa)
```

```
start = Sys.time()
```

```
qtd_amostras = 1000
```

```
p = sum(cadastro_mestre$Y_hi)/N
```

```
proporcoes_ppt_pareto <- numeric(qtd_amostras)
```

```
estimativas_Y_hat <- numeric(qtd_amostras)
```

```
for (i in 1:qtd_amostras) {
```

```
  semente_global = 123 + i
```

```
  set.seed(semente_global)
```

```
  Yhat = c()
```

```
  for (estrato in H) {
```

```
    h_df <- cadastro_mestre %>%
```

```
      filter(h == estrato)
```

```
    amostra_pareto <- h_df %>%
```

```
      mutate(ALEAT = runif(n())) %>%
```

```
      mutate(Q = (ALEAT*(1- pi_hi)) / ((1 - ALEAT) * pi_hi)) %>%
```

```
      group_by(h) %>%
```

```
      arrange(Q) %>%
```

```
      group_modify(~ slice_head(.x, n = unique(.x$m_h))) %>%
```

```
      ungroup()
```

```
    Yhat_h <- amostra_pareto %>%
```

```
      summarize(Yhat = sum(Y_hi/pi_hi))
```

```
    Yhat = rbind(Yhat, Yhat_h)
```

```
}  
estimativas_Y_hat[i] = sum(Yhat)  
}  
  
p_hat = estimativas_Y_hat/N  
  
EQM_p = (1/qtd_amostras) * sum((p_hat - p)^2)  
vies = (1/qtd_amostras) * sum(p_hat - p)  
end = Sys.time()  
end - start
```

ANEXO C – CÓDIGOS PPT DE POISSON CORRELACIONADO ESPACIALMENTE

```

\footnotesize
# =====
# AMOSTRAGEM SCPS
# =====

# CONFIGURAÇÕES INICIAIS =====
start <- Sys.time()
qtd_amostras = 1000

# PREPARAÇÃO DOS DADOS =====
st_crs(cadastro_mestre$geom)
str(cadastro_mestre)

# Extraí os centroides de cada polígono
cadastro_mestre <- cadastro_mestre %>%
  mutate(centroide = st_centroid(geom)) %>%
  mutate(
    coord_x = st_coordinates(centroide)[, 1],
    coord_y = st_coordinates(centroide)[, 2]
  )

names(totais_por_upa)
#aqui mudar de acordo com a variavel que estamos estimando
cadastro_mestre <- cadastro_mestre %>%
  mutate(Y_hi = agua_terreno_hi)

# INICIALIZAÇÃO DAS ESTRUTURAS =====
Yh_hat = list()
upas_amostra = c()
resultado = list()

# SIMULAÇÃO =====
# Loop para gerar as amostras

```

```
# s representa a replicação
for (s in 1:qtd_amostras) {
  semente_global = 123 + s
  set.seed(semente_global)

  # Vetores temporários com os resultados pro estrato
  totais = numeric(length(H))
  names(totais) = H
  upas_amostra_h = c()

  # Loop por cada estrato
  for (estrato in H) {
    h_df <- cadastro_mestre %>%
      filter(h == estrato)

    matriz_auxiliar_estrato = scale(cbind(h_df$coord_x, h_df$coord_y, h_df$pi_hi))
    pik_estrato = h_df$pi_hi

    scps_indices = scps(pik_estrato, matriz_auxiliar_estrato)

    Yh_hat_estrato = sum(h_df$Y_hi[scps_indices] / h_df$pi_hi[scps_indices])
    upas_amostra_h[[as.character(estrato)]] = h_df$codigo_upa[scps_indices]

    # Armazena a estimativa Yh_hat na posição correta do vetor para esta amostra
    totais[[as.character(estrato)]] = Yh_hat_estrato
  }

  # Salvando resultados por replicação
  # Armazena o vetor de estimativas Yh_hat na lista de colunas para a matriz Yh
  resultado[[s]] = totais
}

# PROCESSAMENTO DOS RESULTADOS =====
# Estimativas por estrato (linhas) por replicação (colunas)
Yh_hat = do.call(cbind, resultado)
Yh_hat

# Soma as estimativas por estrato
Y_hat = colSums(Yh_hat)
```

```
# Estimativas da proporção
proporcao_scps = Y_hat/N
proporcao_scps

Y = sum(cadastro_mestre$Y_hi)
p = Y/N

# CÁLCULO DAS MÉTRICAS =====
## EQM
eqm_prop = (1/qtd_amostras) * sum((proporcao_scps - p)^2)
vies = (1/qtd_amostras) * sum((proporcao_scps - p))

t = vies/EP_Vies
p_valor <- 2 * pt(abs(t), df = 999, lower.tail = FALSE)
p_valor

# CV
cv_p = 100 * sqrt(eqm_prop)/p

# RESULTADOS =====
Y
p
eqm_prop
vies
cv_p

end <- Sys.time()
end - start
```